



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Ingeniería Matemática y Computación

Análisis y visualización de desigualdades urbanas en Valencia a partir de datos distritales

Trabajo Fin de Estudios

presentado por: Paloma Gil Franco, Marta Estévez Seoane

Dirigido por: Gustavo Fontana Riera Riera

Fecha: 17 de junio de 2026

Índice de Contenidos

Resumen	VI
Abstract	VII
1. Introducción	1
1.1. Justificación	1
1.2. Planteamiento del problema	1
1.3. Estructura del trabajo	2
2. Contexto y Estado del Arte	3
3. Objetivos concretos y metodología de trabajo	6
3.1. Objetivo general	6
3.2. Objetivos específicos	6
3.3. Metodología del trabajo	7
4. Desarrollo específico de la contribución	9
4.1. Recopilación de datos y construcción de la matriz distrital	9
4.1.1. Planteamiento general y criterios de recopilación	10
4.1.2. Fuentes de información utilizadas	11
4.1.3. Naturaleza híbrida de las fuentes	13
4.1.4. Estructura base de la tabla maestra	19
4.1.5. Problemas de lectura e interpretación de las fuentes	20
4.1.6. Integración territorial y construcción de la tabla inicial	25
4.1.7. Generación de indicadores derivados	30
4.1.8. Resultado de la tabla inicial	31
4.2. Depuración de la matriz de indicadores	31
4.2.1. Criterios generales de depuración	32
4.2.2. Eliminación de variables redundantes	32
4.2.3. Unificación y agregación de variables	34
4.2.4. Normalización y cambio de unidades	38
4.2.5. Apoyo cuantitativo a las decisiones metodológicas	39
4.2.6. Resultado final de la depuración	43

4.3.	Jerarquización de la matriz	43
4.3.1.	Bloques temáticos y subdimensiones	43
4.3.2.	Roles analíticos de las variables	44
4.3.3.	Productos finales de la jerarquización	45
4.4.	Visualización interactiva de la tabla distrital	46
4.4.1.	Lectura de datos y selección de variables numéricas	46
4.4.2.	Construcción de la geometría distrital	47
4.4.3.	Integración de metadatos jerárquicos	48
4.4.4.	Generación del documento HTML	49
4.4.5.	Escritura del mapa y flujo principal	50
4.5.	Descripción del modelo	51
4.5.1.	Justificación metodológica del modelo	51
4.5.2.	Preparación y escalado de los datos	53
4.5.3.	Análisis exploratorio mediante PCA	54
4.5.4.	Elección del número de clusters	56
4.5.5.	Resultado del ajuste con $k = 4$	57
4.6.	Análisis de resultados	59
4.6.1.	Interpretación territorial de los clusters	59
4.6.2.	Variables más influyentes	60
4.6.3.	Variables menos influyentes	62
4.6.4.	Interpretación socioeconómica	62
4.6.5.	Limitaciones del modelo	63
4.7.	Comprobaciones adicionales de robustez	63
4.7.1.	Solución con $k = 3$	63
4.7.2.	Solución con $k = 5$	64
4.7.3.	Comparación entre valores de k	64
5.	Conclusiones y trabajo futuro	66
5.1.	Conclusiones	66
5.2.	Trabajo futuro	66
6.	Bibliografía	68

A. Apéndice metodológico: materiales complementarios del pipeline	70
A.1. Fuentes iniciales y estructura de partida	70
A.2. Scripts principales del pipeline	70
A.3. Tablas finales generadas	71
A.4. Ficheros de control metodológico	71
A.5. Visualización interactiva	72
A.6. Notebook de análisis multivariante	72

Índice de Ilustraciones

4.1. Varianza explicada acumulada por el PCA	54
4.2. Distritos proyectados sobre las dos primeras componentes principales	55
4.3. Comparación de métricas internas para la elección del número de clusters .	56

Índice de Tablas

4.1. Ejemplos de decisiones respaldadas por evidencia cuantitativa	42
4.2. Medias por cluster en variables sintéticas seleccionadas	58
4.3. Anomalías detectadas en la segmentación por clústeres	58
4.4. Variables interpretativas: densidad, renta, paro y pobreza infantil	60
4.5. Variables interpretativas: valor catastral, actividad económica y vivienda turística	60
4.6. Variables interpretativas: hogares unipersonales, zonas verdes y hechos dis- criminatorios	60
4.7. Variables más influyentes	61
4.8. Variables menos influyentes	62
4.9. Comparación de asignación de distritos para $k = 3$, $k = 4$ y $k = 5$	65

Resumen

Este trabajo tiene como objetivo analizar y visualizar las desigualdades urbanas existentes dentro de la ciudad de Valencia mediante técnicas de análisis multivariante y herramientas de visualización interactiva. Para ello, se construyó una base de datos integrada a escala de distrito a partir de fuentes públicas heterogéneas, principalmente del Ayuntamiento de Valencia, del Instituto Nacional de Estadística y de otras fuentes institucionales y complementarias.

El proceso de trabajo se desarrolló en varias fases. En primer lugar, se realizó una selección razonada de indicadores relevantes para el estudio de la vulnerabilidad urbana, tomando como referencia conceptual los ejes utilizados en el Atlas de Vulnerabilidad Urbana y en otros estudios sobre desigualdad territorial. En segundo lugar, se llevó a cabo la integración, depuración y homogeneización de dichos indicadores en una tabla única de distritos. Finalmente, sobre esta base se planteó la aplicación de técnicas de reducción de dimensionalidad, análisis de correlación, clustering y visualización interactiva con el fin de identificar patrones territoriales de desigualdad.

La principal contribución del trabajo consiste en la construcción de una base de datos distrital amplia, coherente y metodológicamente justificada, preparada para el análisis de desigualdades urbanas desde una perspectiva cuantitativa y visual. Esta base permite estudiar de forma conjunta dimensiones demográficas, económicas, educativas, residenciales, ambientales, sociales y de acceso a servicios, proporcionando un soporte útil para la interpretación territorial y para futuros procesos de toma de decisiones.

Palabras clave: desigualdad urbana, vulnerabilidad urbana, análisis multivariante, clustering, visualización interactiva, distritos, Valencia.

Abstract

This dissertation aims to analyse and visualise urban inequalities within the city of Valencia by combining multivariate analysis techniques and interactive visualisation tools. To do so, an integrated district-level database was built from heterogeneous public sources, mainly from the City Council of Valencia, the Spanish National Statistics Institute, and other complementary institutional sources.

The work was developed in several stages. First, a reasoned selection of indicators relevant to urban vulnerability was carried out, taking as a conceptual reference the dimensions used in the Urban Vulnerability Atlas and other territorial inequality studies. Second, the selected indicators were integrated, cleaned and standardised into a single district-level table. Finally, this database was used as the basis for dimensionality reduction, correlation analysis, clustering and interactive visualisation in order to identify territorial patterns of inequality.

The main contribution of this dissertation lies in the construction of a broad, coherent and methodologically justified district-level database specifically designed for the analysis of urban inequalities from a quantitative and visual perspective. This database makes it possible to jointly study demographic, economic, educational, residential, environmental and social dimensions, as well as access to services, thus providing a useful framework for territorial interpretation and for future decision-making processes.

Keywords: urban inequality, urban vulnerability, multivariate analysis, clustering, interactive visualisation, districts, Valencia.

1. Introducción

1.1. Justificación

Las desigualdades urbanas constituyen un fenómeno complejo que no puede entenderse a partir de una única variable. La distribución de la renta, la estructura demográfica, el nivel educativo, la calidad residencial, la disponibilidad de equipamientos, la movilidad o las condiciones ambientales se combinan de forma desigual en el territorio, generando contrastes significativos incluso dentro de una misma ciudad. Por ello, resulta necesario disponer de herramientas que permitan estudiar estas diferencias de forma integrada.

El principal interés de este trabajo es analizar y visualizar las desigualdades urbanas intraurbanas, poniendo de manifiesto cómo la combinación de factores socioeconómicos, urbanos y territoriales influye en las condiciones de vida de la población. Este tipo de análisis puede resultar útil no sólo desde un punto de vista académico, sino también para la planificación urbana y la toma de decisiones públicas, al facilitar la identificación de áreas con mayores niveles de vulnerabilidad relativa.

Aunque existen estudios e indicadores sobre desigualdad territorial, con frecuencia la información aparece dispersa, fragmentada o difícilmente comparable entre sí. En muchos casos, los datos existen, pero no están integrados en una única estructura analítica que permita tratarlos conjuntamente. Por ello, en este trabajo se plantea la construcción de un modelo aplicado a una ciudad concreta, Valencia, con el fin de disponer de un caso de estudio acotado, pero suficientemente rico como para extraer patrones relevantes.

La elección de Valencia responde, además, a la disponibilidad de un volumen amplio de datos abiertos municipales y estadísticos, lo que permite desarrollar una base de datos consistente y metodológicamente justificable. A partir de esa base, se pretende aplicar técnicas de análisis multivariante y representación interactiva que ayuden a comprender mejor la estructura territorial de la desigualdad urbana.

1.2. Planteamiento del problema

Existen antecedentes relevantes tanto en el ámbito académico como en el institucional. Por una parte, la literatura reciente muestra numerosos ejemplos de aplicación de técnicas como el análisis de componentes principales, la reducción de dimensionalidad o los métodos

de clustering para identificar patrones socioeconómicos en áreas urbanas. Por otra parte, en el contexto español, el Atlas de Vulnerabilidad Urbana constituye una referencia fundamental, al proporcionar indicadores e información territorial con un enfoque sistemático y comparativo.

Sin embargo, estos dos enfoques no siempre convergen plenamente. Los estudios académicos suelen aplicar metodologías estadísticas potentes, pero muchas veces sobre ámbitos geográficos alejados del contexto español o con datos menos específicos del entorno urbano local. En cambio, las herramientas institucionales ofrecen una gran riqueza descriptiva, pero no siempre desarrollan una interpretación multivariante profunda ni una visualización interactiva orientada a la exploración analítica.

Este trabajo surge precisamente en ese punto intermedio. Se propone construir una base de datos territorial propia para Valencia, seleccionar variables relevantes para el estudio de la desigualdad urbana y aplicar sobre ellas técnicas multivariantes que permitan sintetizar información, detectar patrones y agrupar distritos con características similares. Finalmente, estos resultados se plantean en conexión con herramientas de visualización interactiva, con el fin de facilitar su interpretación.

1.3. Estructura del trabajo

El trabajo se organiza en varios capítulos. En primer lugar, se presenta el contexto general del problema y el estado del arte en torno a la desigualdad y la vulnerabilidad urbana. Así se podrán detectar los problemas actuales de la visualización de dichos factores. A continuación, se definen los objetivos concretos y la metodología general del estudio.

Posteriormente, se desarrolla la contribución principal del trabajo. Esta parte incluye la recopilación y selección de datos, la construcción de una base de datos unificada a escala de distrito, la limpieza y depuración de la información y la preparación del conjunto final de variables para su análisis. Sobre esta base se plantea la aplicación de técnicas de análisis multivariante, reducción de dimensionalidad, clustering y análisis de relaciones entre variables. Una vez realizado este análisis, se podrán determinar los factores relevantes para el estudio de las desigualdades y vulnerabilidad urbana.

Por último, se exponen las conclusiones del trabajo, sus principales aportaciones y las posibles líneas de trabajo futuro.

2. Contexto y Estado del Arte

El estudio de las desigualdades urbanas ha adquirido una relevancia creciente en los últimos años, en la medida en que se ha consolidado la idea de que las ciudades no constituyen espacios homogéneos, sino territorios internamente fragmentados en los que se concentran de forma desigual recursos, oportunidades y condiciones de vida. Estas diferencias pueden observarse en dimensiones como la renta, el nivel educativo, la estructura demográfica, la calidad de la vivienda, el acceso a servicios, la movilidad o el entorno ambiental, y generan contrastes significativos incluso dentro de una misma ciudad.

La desigualdad urbana puede analizarse como una distribución desigual de recursos, cargas ambientales, servicios y oportunidades dentro del espacio urbano. En esta línea, algunos trabajos han propuesto medir las desigualdades urbanas a partir de la distribución espacial de amenidades y cargas urbanas (Logan y cols., 2021), mientras que otros han mostrado la utilidad de enfoques multiescala para estudiar desigualdades ambientales dentro de la ciudad (Fernández y Wu, 2016). Estas aproximaciones resultan relevantes para este trabajo porque refuerzan la idea de que la desigualdad urbana no debe reducirse a una sola dimensión socioeconómica, sino entenderse como una combinación de factores sociales, territoriales, ambientales y de acceso a recursos.

Desde el punto de vista conceptual, este trabajo se sitúa en la intersección entre los estudios sobre desigualdad urbana y la literatura sobre vulnerabilidad territorial. En el contexto español, una referencia fundamental es el Atlas de Vulnerabilidad Urbana (Ministerio de Transportes, Movilidad y Agenda Urbana, 2022), que ha contribuido a sistematizar la medición de este fenómeno mediante indicadores demográficos, sociales, económicos y residenciales comparables territorialmente. Este tipo de aproximaciones resulta especialmente útil para identificar áreas con mayores dificultades estructurales y para construir marcos de análisis aplicables a distintos contextos urbanos.

Desde el punto de vista de la vulnerabilidad urbana, la literatura reciente ha insistido en la necesidad de integrar dimensiones sociales, territoriales, ambientales e institucionales en sistemas de indicadores capaces de apoyar la planificación estratégica (Feizizadeh, Blaschke, Lakes, y Tajbar, 2018). Asimismo, los índices espaciales de privación han mostrado su utilidad para sintetizar desigualdades territoriales complejas y apoyar análisis vinculados a salud, bienestar y condiciones de vida (Cabrera-Barona, Murphy, Kienberger, y Blaschke, 2015).

En el contexto español, varios trabajos recientes han analizado la persistencia de desigualdades sociales y residenciales en grandes ciudades. Mazorra Rodríguez estudia la evolución de la desigualdad social y la segregación residencial en Madrid, Barcelona y Valencia entre 2001 y 2021 (Mazorra Rodríguez, 2024), mientras que Benassi e Iglesias-Pascual examinan la concentración residencial de población nacida en el extranjero y su relación con desigualdades de renta en el espacio urbano español (Benassi y Iglesias-Pascual, 2023). Estos antecedentes refuerzan la pertinencia de estudiar Valencia como caso urbano específico.

Junto a esta perspectiva conceptual, la literatura académica ha recurrido con frecuencia a técnicas de análisis multivariante para sintetizar grandes volúmenes de información territorial. Métodos como el análisis de componentes principales, el análisis factorial o los procedimientos de clustering permiten reducir dimensionalidad, identificar estructuras latentes y agrupar unidades espaciales con perfiles similares. Su aplicación al ámbito urbano resulta especialmente adecuada cuando se trabaja con fenómenos complejos que no pueden explicarse a partir de una sola variable, como ocurre con la desigualdad, la segregación o la vulnerabilidad social.

Desde el punto de vista metodológico, el uso de técnicas de reducción de dimensionalidad y agrupamiento resulta habitual cuando se trabaja con sistemas amplios de indicadores urbanos. El análisis de componentes principales y el clustering jerárquico se han utilizado, por ejemplo, para clasificar territorios según perfiles socioeconómicos (Bhahari y Kusnawi, 2024). También se han aplicado variantes espaciales del PCA para estudiar vulnerabilidad urbana y ambiental (Foroutan, Hu, Zhang, y Yu, 2024), así como métodos de agrupamiento orientados a identificar áreas urbanas con perfiles diferenciados (Vera y cols., 2022).

Sin embargo, entre ambos enfoques persiste a menudo una cierta desconexión. Por un lado, muchos trabajos académicos aplican metodologías estadísticas avanzadas, pero no siempre detallan el proceso de construcción de la base de datos ni trabajan con información pública fácilmente replicable. Por otro lado, las herramientas institucionales suelen ofrecer una base descriptiva muy valiosa, aunque con menor desarrollo en términos de modelización multivariante o de exploración interactiva de los datos.

En este contexto, el presente trabajo se plantea como una contribución de carácter aplicado. Su objetivo no es únicamente analizar desigualdades urbanas en Valencia, sino también construir la infraestructura de datos necesaria para hacerlo con criterios explícitos de selección, integración, depuración y reproducibilidad. La aportación principal se sitúa,

por tanto, en la articulación de tres elementos que no siempre aparecen conjuntamente: el uso de fuentes públicas heterogéneas, la preparación de una base distrital amplia y coherente, y la orientación posterior hacia técnicas de análisis multivariante y visualización interactiva.

El caso de Valencia resulta especialmente adecuado para este propósito. La ciudad dispone de una cantidad notable de información abierta procedente del Ayuntamiento de Valencia (Ajuntament de València, 2025), del Instituto Nacional de Estadística (Instituto Nacional de Estadística, 2025), del padrón, de anuarios estadísticos, de servicios cartográficos y de otras fuentes institucionales. Esta disponibilidad permite construir una base de datos rica en dimensiones y suficientemente detallada como para abordar desigualdades intraurbanas desde una perspectiva cuantitativa y territorial.

En definitiva, el estado del arte muestra que existe una base conceptual y metodológica sólida para estudiar las desigualdades urbanas mediante indicadores compuestos, análisis multivariante y representación espacial. No obstante, sigue siendo necesaria una labor de integración y estructuración cuando se quiere aplicar este enfoque a un caso urbano concreto utilizando fuentes públicas diversas. Ese es precisamente el espacio en el que se inscribe este trabajo.

3. Objetivos concretos y metodología de trabajo

A partir de las limitaciones detectadas en la literatura y en las fuentes disponibles, se plantea la construcción de una infraestructura de datos que permita integrar, depurar y analizar indicadores urbanos a escala distrital. Esta infraestructura constituye la base sobre la que posteriormente se aplican técnicas de análisis multivariante y visualización interactiva para estudiar las desigualdades urbanas en Valencia.

3.1. Objetivo general

El objetivo general de este trabajo es construir una matriz distrital integrada y un modelo analítico-visual que permitan estudiar las desigualdades urbanas dentro de la ciudad de Valencia a partir de fuentes públicas heterogéneas y técnicas de análisis multivariante.

A diferencia de trabajos centrados únicamente en la aplicación de técnicas estadísticas sobre bases ya preparadas, este estudio incorpora como parte central de la contribución la recopilación, integración, depuración y jerarquización de los indicadores. De este modo, se propone una metodología reproducible y transferible a otros contextos urbanos en los que existan fuentes públicas comparables.

3.2. Objetivos específicos

Los objetivos específicos del trabajo se agrupan en cuatro bloques:

1. Recopilación y construcción de la base de datos

- a) Identificar las dimensiones más relevantes para el estudio de la desigualdad y la vulnerabilidad urbana.
- b) Recopilar datos públicos de distintas fuentes institucionales y estadísticas para la ciudad de Valencia.
- c) Integrar la información en una tabla única y homogénea a escala de distrito.

2. Depuración y preparación de la matriz

- a) Seleccionar y filtrar los indicadores con mayor utilidad analítica.
- b) Reducir redundancias, duplicidades e inconsistencias entre variables.
- c) Jerarquizar las variables según bloque temático, subdimensión y rol analítico.

3. Análisis multivariante

- a) Aplicar técnicas de reducción de dimensionalidad para sintetizar la información contenida en la matriz.
- b) Utilizar métodos de clustering para detectar agrupaciones de distritos con perfiles territoriales similares.
- c) Evaluar la capacidad explicativa de las técnicas aplicadas en relación con la estructura urbana observada.

4. Interpretación y visualización

- a) Interpretar los patrones territoriales obtenidos desde una perspectiva de desigualdad urbana.
- b) Desarrollar herramientas de visualización que faciliten la exploración de los indicadores y resultados.
- c) Valorar la utilidad de la metodología propuesta para su posible aplicación en otros contextos urbanos.

3.3. Metodología del trabajo

La metodología seguida combina revisión conceptual, recopilación sistemática de datos, integración de fuentes heterogéneas, depuración de indicadores, análisis multivariante y visualización interactiva.

En una primera etapa se definió el marco conceptual del estudio. Para ello se revisaron trabajos previos sobre desigualdad urbana, vulnerabilidad territorial, análisis de privación, segregación residencial y técnicas multivariantes aplicadas al análisis urbano. Esta revisión permitió identificar las dimensiones principales que debían estar representadas en la base de datos: estructura demográfica, situación socioeconómica, educación, vivienda, entorno urbano, medio ambiente, acceso a servicios y privación material.

En una segunda etapa se abordó la recopilación de datos. Se revisaron los datos abiertos disponibles para Valencia, especialmente los procedentes del Ayuntamiento de Valencia,

del Instituto Nacional de Estadística y de otras fuentes complementarias. La recopilación no se planteó como una descarga indiscriminada, sino como una selección razonada de indicadores con utilidad analítica para el estudio de la desigualdad urbana. Cuando se detectaron vacíos relevantes, se incorporaron fuentes específicas que permitieran completar dimensiones insuficientemente cubiertas, como la pobreza infantil o la privación material.

En una tercera etapa se procedió a la integración de los datos en una tabla maestra a escala de distrito. Este paso requirió homogeneizar nombres y códigos territoriales, interpretar la estructura de ficheros con formatos distintos, resolver problemas de cabeceras, seleccionar variables útiles y aplicar un criterio temporal claro: cuando un indicador estaba disponible en varios años y medía esencialmente la misma dimensión, se priorizó la versión más reciente.

En una cuarta etapa se llevó a cabo la depuración de la matriz de indicadores. Esta fase incluyó la eliminación de variables redundantes, la sustitución de recuentos absolutos por tasas o porcentajes cuando resultaba metodológicamente más adecuado, la agregación de subcategorías, la construcción de indicadores sintéticos y el uso de correlaciones como apoyo cuantitativo a decisiones inicialmente interpretativas.

En una quinta etapa se jerarquizó la matriz resultante. Cada variable fue clasificada según bloque temático, subdimensión y rol analítico, distinguiendo entre variables activas, variables suplementarias, variables auxiliares y variables de identificación. Esta jerarquización permitió preparar una matriz más clara para la fase posterior de análisis multivariante.

Finalmente, sobre la matriz final se planteó la aplicación de técnicas de análisis multivariante y visualización interactiva. Entre ellas destacan el análisis de componentes principales, el estudio de correlaciones, los métodos de clustering y la construcción de un mapa interactivo por distritos. El objetivo de esta fase fue reducir dimensionalidad, identificar patrones territoriales, agrupar distritos con perfiles similares y facilitar la interpretación espacial de los resultados.

4. Desarrollo específico de la contribución

4.1. Recopilación de datos y construcción de la matriz distrital

El objetivo de esta fase fue construir una base de datos integrada a escala de distrito para la ciudad de Valencia, orientada al estudio de la vulnerabilidad urbana, la desigualdad territorial y las condiciones de vida de la población. La finalidad no fue únicamente reunir datos disponibles, sino seleccionar, organizar y transformar un conjunto amplio de indicadores que permitiera describir dimensiones demográficas, económicas, educativas, residenciales, ambientales, sociales y de acceso a servicios (Ministerio de Transportes, Movilidad y Agenda Urbana, 2022).

La construcción de esta base partió de una constatación metodológicamente importante: la información necesaria existía, pero no aparecía integrada en una única estructura analítica. Los distintos indicadores estaban repartidos entre carpetas temáticas del Ayuntamiento de Valencia (Ajuntament de València, 2025), servicios abiertos del geoportal, tablas del Instituto Nacional de Estadística (Instituto Nacional de Estadística, 2025), hojas de cálculo descargadas manualmente, ficheros `csv`, recursos `geojson` y, en algunos casos, visualizaciones públicas o materiales complementarios que permitían recuperar variables concretas.

En este sentido, la fase inicial tuvo un componente importante de trabajo “de fuerza bruta”: localizar fuentes, descargar ficheros, organizar carpetas temáticas, abrir documentos uno a uno, inspeccionar estructuras internas y decidir qué información podía integrarse realmente en una tabla común. No se trató, por tanto, de ejecutar una única rutina automática de descarga, sino de un proceso acumulativo en el que cada fuente exigió una lectura individual y, con frecuencia, un tratamiento específico.

Por ello, antes de plantear cualquier análisis multivariante, fue necesario desarrollar una fase específica de recopilación, interpretación e integración territorial. Esta etapa constituye una parte central del trabajo, ya que la matriz final no debe entenderse como un archivo auxiliar ya dado, sino como una infraestructura analítica construida expresamente

para hacer posible el análisis posterior.

4.1.1. Planteamiento general y criterios de recopilación

La recopilación de datos no se planteó como una descarga indiscriminada de todo aquello que estuviera disponible sobre Valencia, sino como una tarea guiada por un marco conceptual previo. La desigualdad urbana es un fenómeno multidimensional: no se expresa únicamente en la renta, ni solo en la vivienda, ni solo en el acceso a servicios. Por el contrario, surge de la combinación desigual de estructuras demográficas, oportunidades económicas, condiciones residenciales, entorno urbano, acceso a equipamientos, calidad ambiental y formas diversas de vulnerabilidad social.

Con este fin, se tomaron como referencia la literatura sobre desigualdad urbana y vulnerabilidad territorial, así como el Atlas de Vulnerabilidad Urbana y otros materiales del INE (Ministerio de Transportes, Movilidad y Agenda Urbana, 2022; Instituto Nacional de Estadística, 2025). Este marco permitió identificar dimensiones habituales en los estudios de vulnerabilidad y evitar una selección puramente intuitiva de variables.

La lógica de trabajo puede resumirse en cinco pasos:

1. identificar dimensiones relevantes para el estudio de la vulnerabilidad urbana;
2. revisar las fuentes públicas disponibles para Valencia;
3. seleccionar indicadores con utilidad analítica real;
4. detectar vacíos temáticos y buscar fuentes complementarias cuando fuera necesario;
5. unificar toda la información a una misma escala territorial: el distrito.

En la práctica, una variable se consideraba candidata a entrar en la tabla cuando describía una dimensión central del fenómeno estudiado, era interpretable territorialmente, podía compararse entre distritos, presentaba una calidad mínima de dato y no duplicaba de forma evidente otra variable ya incorporada. En cambio, tendían a descartarse columnas puramente administrativas, etiquetas textuales sin valor analítico, recuentos sin contexto territorial o medidas excesivamente específicas cuya interpretación resultaba débil fuera de su ámbito técnico original.

Las dimensiones prioritarias fueron las siguientes:

- indicadores socioeconómicos: renta, desigualdad, paro, actividad económica, pobreza y privación material;
- indicadores demográficos: estructura por edades, envejecimiento, tamaño del hogar, población extranjera y composición familiar;
- indicadores educativos: nivel de estudios, escolarización, alumnado por etapas, centros y titularidad;
- indicadores residenciales y urbanísticos: parque de vivienda, antigüedad, valor catastral, licencias, solares, densidad y características del entorno construido;
- indicadores ambientales: zonas verdes, arbolado, ruido, contaminación y otros recursos ambientales;
- indicadores de acceso a servicios y equipamientos: recursos sociales, centros educativos, recursos municipales, servicios públicos, conectividad y movilidad;
- indicadores de seguridad y convivencia: policía local, bomberos, hechos discriminatorios y otras aproximaciones disponibles en fuentes públicas.

Este marco no se utilizó como una plantilla rígida, sino como una guía para evitar dos riesgos: acumular muchas columnas solo porque estaban disponibles, o limitar el análisis a aquellas dimensiones con datos más fáciles de obtener.

4.1.2. Fuentes de información utilizadas

Las fuentes empleadas pueden agruparse en tres grandes bloques: fuentes municipales, fuentes estadísticas de ámbito más general y fuentes complementarias específicas. Esta distinción permite ordenar el origen de los datos antes de describir el procedimiento técnico seguido para reconstruirlos e integrarlos en la tabla distrital.

Fuentes municipales

La mayor parte de la información procede del Ayuntamiento de Valencia (Ajuntament de València, 2025), tanto del geoportal y sus servicios abiertos como de los ficheros estadísticos temáticos descargados en formato `xlsx`, `csv` y `geojson`. Dentro de este bloque se recopilaron, entre otros, indicadores de urbanismo e infraestructuras, movilidad y tráfico, medio ambiente, recursos municipales, actividad económica, edificación y vivienda, padrón

municipal, encuesta de características demográficas y de vivienda, educación, bienestar social y consultas electorales.

Este bloque fue el núcleo de la base de datos, ya que ofrecía información muy específica sobre la realidad urbana de Valencia y una granularidad territorial suficientemente útil para construir una tabla distrital amplia. Además, su diversidad temática permitió que la base no se limitara a una lectura socioeconómica estrecha, sino que incorporara también información sobre entorno construido, servicios públicos, movilidad, calidad urbana y acceso a recursos.

Organización material de las carpetas de trabajo

La recopilación no se apoyó únicamente en una navegación abstracta por fuentes, sino también en una organización física de carpetas de trabajo. Los materiales se fueron agrupando temáticamente en directorios como `Padrón municipal`, `Actividad económica`, `Edificación y vivienda`, `Educación`, `Bienestar social`, `Recursos municipales`, `Renta`, `consumo y precios`, `Consultas electorales`, `Medio ambiente y deporte` o `anuario`. Esta organización permitió trabajar por bloques relativamente homogéneos y no como una sola colección indiferenciada de archivos.

Además, esta estructura de carpetas sirvió después como base para reconstruir el origen de cada parte de la tabla mediante el script unificado en Python. De este modo, la organización material del trabajo no fue solo una cuestión práctica, sino también una parte de la trazabilidad metodológica del proceso.

INE y fuentes estadísticas relacionadas

Se incorporaron también indicadores procedentes del INE (Instituto Nacional de Estadística, 2025), especialmente los relacionados con renta, desigualdad, demografía, nivel educativo y otros descriptores socioeconómicos. Parte de esta información se obtuvo de tablas descargadas y parte a partir de materiales visuales o capturas que permitían recuperar valores distritales concretos cuando no existía una tabla local claramente integrada en el resto del pipeline.

Además, el Atlas de Vulnerabilidad Urbana (Ministerio de Transportes, Movilidad y Agenda Urbana, 2022) sirvió como referencia metodológica adicional para identificar variables clave y detectar lagunas en la base de datos inicial. No se utilizó como una plantilla que hubiera que reproducir exactamente, sino como un marco orientador para

reconocer qué tipos de indicadores resultan habituales en el análisis de la vulnerabilidad y qué dimensiones convenía no dejar fuera.

Fuentes complementarias

Finalmente, se añadieron fuentes complementarias externas cuando aportaban variables especialmente valiosas y no disponibles en los repositorios anteriores. Un ejemplo importante fue la tasa de pobreza infantil distrital de 2021, obtenida a partir de la visualización pública en Tableau de Albert Arcarons (Arcarons, 2021). También se utilizaron artículos periodísticos y visualizaciones públicas para recuperar variables concretas, como algunas relacionadas con privación material o condiciones de vida, siempre que fueran territorializables a nivel de distrito y suficientemente claras como para integrarlas en la tabla.

Esta incorporación de fuentes complementarias no respondió a una lógica acumulativa, sino a una búsqueda dirigida. Cuando una dimensión importante del fenómeno estaba débilmente representada, como pobreza infantil o privación material, se buscaron fuentes adicionales capaces de cubrir ese vacío. Esto permitió pasar de una lógica meramente descriptiva, basada en aprovechar lo disponible, a una lógica más analítica, orientada a completar un sistema de indicadores con cobertura temática razonable.

4.1.3. Naturaleza híbrida de las fuentes

La tabla inicial no partió de un único fichero ya preparado, sino de una fase previa de recopilación intensiva de fuentes heterogéneas. El principal reto no fue la falta de información, sino la necesidad de reunir, ordenar y hacer compatibles materiales muy distintos entre sí: ficheros `xlsx` descargados manualmente, tablas `csv`, capas geográficas, servicios web y bloques de datos incorporados manualmente a partir de información externa.

La reconstrucción del pipeline inicial permitió distinguir tres tipos de origen:

- **fuentes con descarga directa por URL**, como ciertas capas del geoportal municipal consumidas mediante servicios `json`, `geojson` o ArcGIS;
- **fuentes descargadas manualmente y conservadas en carpetas locales**, que constituyeron la mayor parte del trabajo distrital inicial;
- **bloques incorporados manualmente**, en los que los valores no procedían de un

fichero descargable claramente recuperable dentro del pipeline, sino de una tabla introducida directamente en el script.

Esta distinción es metodológicamente importante porque permite describir el proceso de forma honesta. La tabla inicial no se construyó a partir de una única rutina automática de descarga masiva, sino combinando descargas directas, almacenamiento manual de ficheros fuente y posteriores fases de integración programática.

Reconstrucción reproducible de las fuentes iniciales

Con el fin de documentar esta fase, se elaboró un script unificado en Python que reconstruye las fuentes originales empleadas en la primera versión de la tabla. Su función no es todavía derivar ni depurar variables complejas, sino reconstituir el punto de partida material del pipeline y dejar constancia de cómo se obtuvo cada bloque.

Listing 4.1: Clasificación de fuentes según su origen dentro del pipeline inicial

```
1 from dataclasses import dataclass
2
3 @dataclass(frozen=True)
4 class FolderSource:
5     name: str
6     relative_dir: str
7     origin_scripts: tuple[str, ...]
8     note: str
9
10 @dataclass(frozen=True)
11 class HttpSource:
12     name: str
13     url: str
14     filename: str
15     origin_scripts: tuple[str, ...]
16     note: str
17
18 @dataclass(frozen=True)
19 class ManualSource:
20     name: str
21     origin_scripts: tuple[str, ...]
22     note: str
```

Listing 4.2: Registro explícito de carpetas y fuentes del pipeline inicial

```
1 from pathlib import Path
2
3 LEGACY_ROOT = Path(r"C:\Users\paloma.gil\Desktop\otros\Valencia")
4
5 FOLDER_SOURCES = [
6     FolderSource(
7         name="padron_municipal",
8         relative_dir="Padrón municipal",
9         origin_scripts=("crear_tabla_distritos.py",),
10        note="Tablas demograficas y educativas descargadas manualmente"
11    ),
12    FolderSource(
13        name="actividad_economica",
14        relative_dir="Actividad económica",
15        origin_scripts=("crear_tabla_distritos.py",),
16        note="Hoteles, terrazas, oficinas bancarias y otras actividades"
17    ),
18    FolderSource(
19        name="edificacion_vivienda",
20        relative_dir="Edificación y vivienda",
21        origin_scripts=("crear_tabla_distritos.py",),
22        note="Mercado residencial, licencias, inmuebles y valores"
23    ),
24 ]
25
26 HTTP_SOURCES = [
27     HttpSource(
28         name="geojson_zonas_verdes",
29         url="https://geoportal.valencia.es/apps/OpenData/jardines/zonasverdes.
30         geojson",
31         filename="zonasverdes.geojson",
32         origin_scripts=("crear_tabla_distritos.py",),
33         note="Capa espacial descargable por URL"
34     ),
```

```
34 ]
35
36 MANUAL_SOURCES = [
37     ManualSource(
38         name="pobreza_infantil_2021",
39         origin_scripts=("crear_tabla_distritos.py",),
40         note="Valores incorporados manualmente desde visualizacion externa"
41     ),
42 ]
```

La utilidad de esta formalización es doble. Por una parte, permite reconstruir y documentar qué materiales estuvieron realmente en la base del trabajo. Por otra, obliga a distinguir entre lo que puede regenerarse automáticamente y lo que solo puede documentarse como parte del proceso real seguido.

Fuentes locales descargadas manualmente

En los casos en que el proceso real se apoyaba en carpetas ya descargadas manualmente, el script no intenta fingir una automatización retrospectiva inexistente. En su lugar, recorre dichas carpetas, selecciona los ficheros relevantes y los copia a un espacio de trabajo reproducible, dejando constancia de su origen.

Listing 4.3: Reconstrucción de fuentes locales descargadas manualmente

```
1 def materialize_folder_sources():
2     rows = []
3     for source in FOLDER_SOURCES:
4         source_folder = LEGACY_ROOT / source.relative_dir
5         target_root = LOCAL_OUT / slugify(source.name)
6
7         matched = iter_relevant_files(source_folder)
8         for file_path in matched:
9             relative = file_path.relative_to(source_folder)
10            out_path = target_root / relative
11            ensure_dir(out_path.parent)
12            shutil.copy2(file_path, out_path)
13            rows.append({
14                "grupo": source.name,
15                "metodo": "mirror_local_download",
```

```
16         "estado": "copied",
17         "origen_fichero": str(file_path),
18         "destino": str(out_path),
19     })
20     return rows
```

Listing 4.4: Filtrado de ficheros realmente relevantes dentro de cada carpeta temática

```
1 ALLOWED_SUFFIXES = {".csv", ".xlsx", ".xls", ".json", ".geojson", ".kmz"}
2 SKIP_TOKENS = {"desktop.ini", "~$", ".tmp", ".bak"}
3
4 def iter_relevant_files(folder: Path):
5     for path in sorted(folder.rglob("*")):
6         if not path.is_file():
7             continue
8         if path.suffix.lower() not in ALLOWED_SUFFIXES:
9             continue
10        if any(token.lower() in path.name.lower() for token in SKIP_TOKENS):
11            continue
12        yield path
13
14 for source in FOLDER_SOURCES:
15     source_folder = LEGACY_ROOT / source.relative_dir
16     matched_files = list(iter_relevant_files(source_folder))
17     print(source.name, len(matched_files))
```

Este tipo de operaciones refleja cómo se trabajó en la práctica. La mayoría de las fuentes distritales importantes no se obtenían mediante una llamada web simple, sino que estaban almacenadas en carpetas temáticas y debían ser localizadas, abiertas e interpretadas una a una.

Fuentes con descarga directa y bloques manuales

Algunas fuentes sí podían recuperarse directamente mediante URL, especialmente capas geográficas del geoportal municipal o recursos abiertos servidos en formato `json` o `geojson`.

Listing 4.5: Descarga directa de fuentes HTTP preservadas en los scripts originales

```
1 def materialize_http_sources(download_http: bool, force: bool):
2     rows = []
3     for source in HTTP_SOURCES:
4         out_path = HTTP_OUT / source.filename
5         status = "skipped_http"
6
7         if download_http:
8             with urllib.request.urlopen(source.url, timeout=60) as response:
9                 data = response.read()
10                out_path.write_bytes(data)
11                status = "downloaded"
12
13            rows.append({
14                "grupo": source.name,
15                "metodo": "direct_http",
16                "estado": status,
17                "url": source.url,
18                "destino": str(out_path),
19            })
20     return rows
```

Por último, hubo bloques cuyo origen no era una descarga automatizable dentro del pipeline, sino una incorporación manual de datos. En estos casos, el script no genera una falsa descarga, sino que los documenta expresamente como fuentes manuales.

Listing 4.6: Documentación explícita de bloques incorporados manualmente

```
1 def materialize_manual_sources():
2     rows = []
3     for source in MANUAL_SOURCES:
4         rows.append({
5             "grupo": source.name,
6             "metodo": "manual_table",
7             "estado": "manual_only",
8             "origen_scripts": " | ".join(source.origin_scripts),
9             "nota": source.note,
10        })
11     return rows
```

En la ejecución correspondiente a este trabajo se reconstruyeron **243 ficheros crudos** procedentes de carpetas locales, se identificaron **3 fuentes con descarga HTTP directa** y se documentaron **2 bloques manuales**. Este balance confirma que la mayor parte de la tabla inicial se apoyó en ficheros previamente descargados y organizados manualmente, no en un único sistema automático de adquisición.

4.1.4. Estructura base de la tabla maestra

Desde el inicio se fijó la unidad de análisis en el distrito. Esta decisión respondió a que la mayor parte de las fuentes más robustas, comparables y completas estaban disponibles a esa escala. Trabajar por distrito permitió integrar fuentes muy distintas sin mezclar niveles territoriales incompatibles ni forzar agregaciones artificiales.

La tabla principal se estructuró, por tanto, con una fila por cada uno de los 19 distritos de Valencia y una columna por indicador. Además, se incorporó una fila auxiliar para registrar la categoría temática de cada columna.

Listing 4.7: Inicialización de la tabla distrital de partida

```
1 DISTRICTS = [  
2     ("1", "CIUTAT VELLA"),  
3     ("2", "L'EIXAMPLE"),  
4     ("3", "EXTRAMURS"),  
5     ...  
6     ("19", "POBLATS DEL SUD"),  
7 ]  
8  
9 with SCAFFOLD_CSV.open("w", encoding="utf-8-sig", newline="") as handle:  
10     writer = csv.writer(handle)  
11     writer.writerow(["codigo", "nombre"])  
12     writer.writerow(["__categoria__", "CATEGORIA"])  
13     for code, name in DISTRICTS:  
14         writer.writerow([code, name])
```

Listing 4.8: Creación programática de la tabla maestra y de la fila `__categoria__`

```
1 import pandas as pd  
2  
3 def create_master_table():  
4     districts = pd.DataFrame(DISTRICTS, columns=["codigo", "nombre"])
```

```
5 master = districts.copy()
6 category_row = {"codigo": "__categoria__", "nombre": "CATEGORIA"}
7 return master, category_row
8
9 maestra, fila_categoria = create_master_table()
```

Este esqueleto no contenía todavía indicadores, pero fijaba la lógica del resto del pipeline: toda fuente nueva debía terminar acoplándose a una tabla con una fila por distrito. La fila `__categoria__` permitió clasificar temáticamente las columnas desde las primeras versiones de la tabla, en lugar de dejar esa tarea para el final.

Listing 4.9: Actualización de la fila de categorías al incorporar nuevas variables

```
1 def register_categories(category_row: dict, columns: list[str], source_category:
   str):
2     for column in columns:
3         if column not in {"codigo", "nombre", "Distrito"}:
4             category_row[column] = source_category
5
6 columnas_padron = [
7     "Padron 2025 | Poblacion total [n]",
8     "Padron 2025 | Edad media [años]",
9     "Padron 2025 | Poblacion extranjera [%]",
10 ]
11
12 register_categories(fila_categoria, columnas_padron, "Demografia")
```

Desde un punto de vista metodológico, esta decisión refleja que la base no se construyó solo como una matriz numérica, sino como una estructura que ya desde su origen incorporaba una primera interpretación temática de sus variables.

4.1.5. Problemas de lectura e interpretación de las fuentes

Una de las razones por las que esta fase fue especialmente exigente es que la dificultad no residía solo en descargar ficheros, sino en interpretarlos correctamente. Muchas fuentes distritales útiles estaban bien documentadas desde el punto de vista administrativo, pero no preparadas para una integración directa en una tabla analítica. Esto obligó a desarrollar una lógica de lectura flexible, más cercana a la inspección y reconstrucción de estructuras

que a la mera importación de datos.

Heterogeneidad de formatos

Las fuentes no compartían ni formato ni estructura interna. Algunas llegaban como `csv` sencillos con una fila por distrito; otras como libros Excel con varias hojas, múltiples bloques temporales o cabeceras partidas; otras como capas geográficas o servicios abiertos; y otras como recursos parciales integrables solo tras una lectura manual o semimanual.

Listing 4.10: Lectura flexible según el formato original del fichero

```
1 def load_raw_source(path: Path, sheet_name=0):
2     suffix = path.suffix.lower()
3
4     if suffix == ".csv":
5         return pd.read_csv(path)
6     if suffix in {".xlsx", ".xls"}:
7         return pd.read_excel(path, sheet_name=sheet_name, header=None)
8     if suffix in {".json", ".geojson"}:
9         return pd.read_json(path)
10
11     raise ValueError(f"Formato no soportado: {path.suffix}")
```

Cabeceras dobles, bloques temporales y filas no distritales

Varias tablas no tenían una cabecera utilizable en la primera fila, sino dos niveles de encabezado o una combinación de subtítulo y variable específica. En estos casos, una lectura convencional con `pandas` podía producir nombres de columna poco informativos. Por ello, resultó más robusto leer la hoja sin confiar en la cabecera original y reconstruir los encabezados combinando varias filas.

Listing 4.11: Reconstrucción de cabeceras a partir de dos filas

```
1 import re
2 import pandas as pd
3
4 def clean_header(text):
5     if text is None:
6         return ""
```

```
7     value = str(text).replace("\n", " ").replace("\r", " ")
8     return re.sub(r"\s+", " ", value).strip(" |")
9
10 def build_headers_from_two_rows(df_raw, row_a=2, row_b=3):
11     headers = {}
12     header_a = df_raw.iloc[row_a]
13     header_b = df_raw.iloc[row_b]
14
15     for col_idx in range(1, df_raw.shape[1]):
16         a = clean_header(header_a.iloc[col_idx])
17         b = clean_header(header_b.iloc[col_idx])
18         if a and b and a != b:
19             headers[col_idx] = f"{a} | {b}"
20         else:
21             headers[col_idx] = b or a
22
23     return headers
```

Listing 4.12: Carga de una hoja Excel con cabecera reconstruida

```
1 def load_excel_with_rebuilt_headers(path, sheet_name=0, row_a=2, row_b=3,
2     data_start=4):
3     df_raw = pd.read_excel(path, sheet_name=sheet_name, header=None)
4     headers = build_headers_from_two_rows(df_raw, row_a=row_a, row_b=row_b)
5     body = df_raw.iloc[data_start:].copy()
6     body = body.rename(columns=headers)
7     body = body.reset_index(drop=True)
8     return body
```

Otra dificultad habitual fue la coexistencia de varios años o varios bloques temáticos dentro de una misma hoja. En estos casos era necesario identificar dónde empezaba el bloque territorial realmente útil, qué filas correspondían a distritos y qué filas eran subtítulos, separadores o agregados globales.

Listing 4.13: Aislamiento de un bloque distrital dentro de una hoja con varios apartados

```
1 def locate_block_start(df_raw, marker="Distrito"):
2     for row_idx in range(df_raw.shape[0]):
3         row_text = " | ".join(str(value) for value in df_raw.iloc[row_idx].tolist
```

```
    ())
4     if marker.lower() in row_text.lower():
5         return row_idx
6     raise ValueError(f"No se encontro el marcador {marker!r}")
7
8 def slice_district_block(df_raw, marker="Distrito", max_rows=40):
9     start = locate_block_start(df_raw, marker=marker)
10    return df_raw.iloc[start:start + max_rows].copy()
```

No todas las filas de los ficheros correspondían a distritos reales. En muchos casos aparecían totales municipales, subtotales, etiquetas auxiliares o desgloses no directamente integrables. Una estrategia frecuente consistía en reconocer patrones como el código distrital seguido de un punto.

Listing 4.14: Detección de filas realmente distritales

```
1 import re
2
3 def get_district_code(label):
4     text = str(label).strip()
5     match = re.match(r"^\s*(\d+)\.\s", text)
6     if match:
7         return str(int(match.group(1)))
8     return None
```

Listing 4.15: Extracción de observaciones distritales a partir de una hoja cruda

```
1 def extract_district_rows(df_raw, label_col=0):
2     rows = []
3
4     for _, row in df_raw.iterrows():
5         code = get_district_code(row.iloc[label_col])
6         if code is None:
7             continue
8         rows.append({
9             "codigo": code,
10            "nombre_origen": str(row.iloc[label_col]).strip(),
11            "values": row.tolist(),
12        })
```

```
13  
14     return rows
```

Selección de columnas útiles

La selección de columnas tampoco se resolvía simplemente por tipo de dato. Aunque se priorizaban columnas numéricas o convertibles a número, el criterio final combinaba varios elementos: comparabilidad real entre distritos, interés sustantivo, interpretabilidad territorial, ausencia de duplicidad inmediata y compatibilidad con la unidad de análisis elegida.

Listing 4.16: Selección inicial de columnas numéricas potencialmente útiles

```
1 def parse_es_number(value):  
2     if pd.isna(value):  
3         return None  
4     text = str(value).strip()  
5     if not text or text == "-":  
6         return None  
7     text = text.replace("%", "").replace(" ", "")  
8     if "," in text and "." in text:  
9         text = text.replace(".", "").replace(",", ".")  
10    elif "," in text:  
11        text = text.replace(",", ".")  
12    return float(text)  
13  
14 def choose_useful_numeric_columns(df, min_non_null=3):  
15     useful = []  
16     for column in df.columns:  
17         parsed = df[column].map(lambda x: parse_es_number(x) if str(x).strip()  
18                                else None)  
19         if parsed.notna().sum() >= min_non_null:  
20             useful.append(column)  
21     return useful
```

Listing 4.17: Construcción de un bloque limpio con código distrital y variables útiles

```
1 def build_clean_block(df_raw, label_col, selected_columns):  
2     district_rows = []
```

```
3
4     for _, row in df_raw.iterrows():
5         code = get_district_code(row.iloc[label_col])
6         if code is None:
7             continue
8
9         record = {"codigo": code}
10        for source_col, final_name in selected_columns.items():
11            record[final_name] = row.iloc[source_col]
12        district_rows.append(record)
13
14    return pd.DataFrame(district_rows)
```

Este cribado nunca sustituyó por completo la revisión sustantiva. La decisión final sobre si una variable interesaba o no dependía también de su capacidad para describir una dimensión relevante del fenómeno estudiado.

4.1.6. Integración territorial y construcción de la tabla inicial

Una vez definidas las fuentes relevantes y fijada la escala territorial, el trabajo principal consistió en integrar todas las variables seleccionadas en una única tabla maestra. Este paso fue uno de los más laboriosos del proceso, ya que las fuentes no compartían formato, estructura de cabeceras, nomenclatura territorial ni lógica temporal.

Homogeneización de nombres y códigos

Una vez detectadas las filas distritales, resultaba necesario homogeneizar los nombres de distrito y sus códigos. Distintas fuentes podían utilizar variantes ortográficas, tildes, mayúsculas o denominaciones parciales que impedían una unión directa entre tablas.

Listing 4.18: Normalización básica de identificadores territoriales

```
1 def normalizar_distrito(valor: str) -> str:
2     return str(valor).strip().upper()
```

Listing 4.19: Normalización de nombres con diccionario de equivalencias

```
1 DISTRICT_ALIASES = {
2     "L OLIVERETA": "L'OLIVERETA",
3     "POBLATS MARITIMS": "POBLATS MARÍTIMS",
```

```
4     "CAMINS AL GRAU ": "CAMINS AL GRAU",  
5 }  
6  
7 def canonicalize_district_name(name: str) -> str:  
8     clean = normalizar_distrito(name)  
9     return DISTRICT_ALIASES.get(clean, clean)
```

Aunque estas funciones son sencillas, ilustran una de las operaciones más repetidas del pipeline: antes de unir una fuente a la tabla maestra, era necesario traducir sus etiquetas territoriales a una forma compatible con el resto del sistema.

Unión incremental de bloques

La integración se abordó de manera incremental. Cada nueva fuente era revisada, interpretada y transformada antes de unirse a la tabla principal. El procedimiento general consistió en entender la estructura del fichero, identificar columnas útiles, comprobar el nivel territorial efectivo del dato, homogeneizar nombres y códigos de distrito y decidir si la nueva información debía complementar, sustituir o ampliar la tabla ya existente.

Listing 4.20: Carga y unión progresiva de fuentes por distrito

```
1 import pandas as pd  
2  
3 maestra = pd.read_csv(BASE_DIR / "Resultados" / "tabla_por_distritos_limpia.csv")  
4  
5 nueva_fuente = pd.read_excel(BASE_DIR / "Datos" / "educacion_anuario.xlsx")  
6 nueva_fuente["Distrito"] = nueva_fuente["Distrito"].map(normalizar_distrito)  
7 maestra["Distrito"] = maestra["Distrito"].map(normalizar_distrito)  
8  
9 columnas utiles = ["Distrito", "Educacion primaria [%]", "Educacion superior [%]  
10                    "]  
11  
12 maestra = maestra.merge(  
13     nueva_fuente[columnas utiles],  
14     on="Distrito",  
15     how="left"
```

Listing 4.21: Función reutilizable para acoplar un bloque a la tabla maestra

```
1 def attach_block(master, category_row, source_df, source_category):
2     source_df = source_df.copy()
3     source_df["codigo"] = source_df["codigo"].astype(str)
4
5     new_columns = [col for col in source_df.columns if col != "codigo"]
6     register_categories(category_row, new_columns, source_category)
7
8     merged = master.merge(source_df, on="codigo", how="left")
9     return merged, category_row
```

Listing 4.22: Especificación simplificada de bloques para ensamblar la tabla inicial

```
1 SOURCE_PIPELINE = [
2     {
3         "path": LEGACY_ROOT / "Padrón municipal" / "padron_2025.xlsx",
4         "sheet_name": 0,
5         "category": "Demografia",
6         "loader": lambda raw: build_clean_block(
7             raw,
8             label_col=0,
9             selected_columns={
10                 1: "Padron 2025 | Poblacion total [n]",
11                 2: "Padron 2025 | Edad media [años]",
12                 3: "Padron 2025 | Poblacion extranjera [%]",
13             },
14         ),
15     },
16     {
17         "path": LEGACY_ROOT / "Educación" / "educacion_anuario.xlsx",
18         "sheet_name": 0,
19         "category": "Educacion",
20         "loader": lambda raw: build_clean_block(
21             raw,
22             label_col=0,
23             selected_columns={
24                 4: "Educacion | Alumnado total [n]",
25                 7: "Educacion | Centros publicos [n]",
```

```
26         },  
27     ),  
28 },  
29 ]
```

Este tipo de operaciones no agota la complejidad real del proceso, pero muestra con claridad la lógica incremental con la que se fue construyendo la tabla maestra. En la práctica, una buena parte del trabajo consistió en repetir este ciclo sobre fuentes diferentes, con problemas distintos en cada caso.

Criterio temporal y solapamientos

La tabla maestra se fue ampliando bloque a bloque, pero no de forma indiscriminada. Cada nueva integración obligaba a decidir si la fuente añadía información nueva, si actualizaba una dimensión ya presente o si duplicaba algo que otra fuente cubría mejor.

Uno de los criterios metodológicos fundamentales fue la prioridad temporal. Cuando una variable ya existía y aparecía de nuevo para un año más reciente, se mantenía la versión más actual y no se duplicaba el indicador, salvo que el nuevo dato midiera realmente algo distinto.

Listing 4.23: Selección de la versión más reciente de un indicador

```
1 def elegir_version_mas_reciente(columnas, raiz):  
2     candidatas = [c for c in columnas if raiz.lower() in c.lower()]  
3     if not candidatas:  
4         return None  
5  
6     def extraer_ano(nombre):  
7         for token in nombre.replace("[", " ").replace("]", " ").split():  
8             if token.isdigit() and len(token) == 4:  
9                 return int(token)  
10        return -1  
11  
12    return max(candidatas, key=extraer_ano)
```

No obstante, esta prioridad temporal no se aplicó de forma ciega. Hubo casos en los que dos variables de años distintos coexistieron temporalmente en la tabla porque, aun siendo cercanas, no medían exactamente lo mismo o porque la comparación podía resultar

útil en una fase posterior.

Listing 4.24: Orquestación simplificada de la construcción de la tabla inicial

```
1 def build_initial_district_table(source_blocks):
2     master, category_row = create_master_table()
3
4     for block in source_blocks:
5         raw = load_raw_source(block["path"], sheet_name=block.get("sheet_name",
6         0))
7         clean_block = block["loader"](raw)
8         master, category_row = attach_block(
9             master,
10            category_row,
11            clean_block,
12            source_category=block["category"],
13        )
14
15     category_df = pd.DataFrame([category_row])
16     return pd.concat([category_df, master], ignore_index=True)
```

Listing 4.25: Guardado de la primera tabla distrital integrada

```
1 OUTPUT_CSV = Path(
2     r"C:\Users\paloma.gil\Desktop\otros\Valencia\Resultados\
3     tabla_por_distritos_limpia.csv"
4 )
5
6 tabla_inicial = build_initial_district_table(SOURCE_PIPELINE)
7
8 tabla_inicial.to_csv(
9     OUTPUT_CSV,
10    index=False,
11    encoding="utf-8-sig"
12 )
```

4.1.7. Generación de indicadores derivados

La construcción de la tabla no consistió únicamente en importar columnas existentes. En muchos casos fue necesario crear indicadores derivados para mejorar la comparabilidad territorial y la interpretabilidad sustantiva del conjunto.

No siempre bastaba con conservar el dato bruto. Un recuento por distrito podía resultar engañoso si no se tenía en cuenta el tamaño del distrito, su población o su superficie. Por ello, además de los valores absolutos, se generaron columnas normalizadas cuando tenía sentido hacerlo.

Listing 4.26: Ejemplo de creación de indicadores derivados

```
1 df["Centros sociales [por_1000_hab]"] = (  
2     df["Centros sociales [n]"] / df["Poblacion total [n]"] * 1000  
3 )  
4  
5 df["Zonas verdes [por_km2]"] = (  
6     df["Zonas verdes [m2]"] / df["Superficie [km2]"]  
7 )
```

En otros casos, el interés no estaba solo en conocer el valor distrital de un indicador, sino en situarlo respecto a una referencia más amplia. Esto ocurrió, por ejemplo, con la pobreza infantil, para la que se incorporaron diferencias respecto a la Comunitat Valenciana y al conjunto nacional.

Listing 4.27: Comparación con referencias externas

```
1 df["Pobreza infantil 2021 | dif C. Valenciana [pp]"] = (  
2     df["Pobreza infantil 2021 | Tasa distrito [%]"] - 29.8  
3 )  
4  
5 df["Pobreza infantil 2021 | dif nacional [pp]"] = (  
6     df["Pobreza infantil 2021 | Tasa distrito [%]"] - 28.9  
7 )
```

También se incorporaron indicadores de privación material de los hogares, considerados especialmente relevantes para captar dimensiones de vulnerabilidad cotidiana que no siempre quedan bien recogidas por la renta o el paro. Estos indicadores aportan una lectura más inmediata de la capacidad real de los hogares para afrontar gastos, mantener

equipamientos básicos o sostener determinados patrones mínimos de vida social (Arcarons, 2021).

4.1.8. Resultado de la tabla inicial

El resultado de esta fase fue una tabla distrital amplia, construida a partir de fuentes heterogéneas, organizada por categorías temáticas y estructurada con una fila por distrito. Esta tabla inicial no constituía todavía la matriz final del análisis multivariante, sino el punto de partida sobre el que posteriormente se aplicarían los procesos de depuración, reducción de redundancias y jerarquización conceptual.

Esta distinción es importante porque evita confundir tres momentos diferentes del trabajo: recopilación e integración de datos, depuración y jerarquización de la matriz, y análisis multivariante propiamente dicho. Aunque en la práctica estos momentos se relacionan entre sí, cada uno responde a una finalidad metodológica distinta.

4.2. Depuración de la matriz de indicadores

La depuración de la matriz distrital constituyó una fase metodológica central del trabajo. No se trató únicamente de reducir el número de columnas por motivos prácticos, sino de transformar una base de datos inicial muy extensa y heterogénea en una matriz analítica comparable, interpretable y reproducible. En este sentido, uno de los aportes diferenciales del TFM consiste en formalizar de manera explícita el procedimiento seguido para pasar de una tabla inicial sobredimensionada a una tabla final adecuada para el análisis multivariante.

La tabla integrada de partida contenía 978 columnas para 19 distritos. En ella coexistían recuentos absolutos, porcentajes, densidades, variables duplicadas procedentes de distintas fuentes, desagregaciones temáticas muy finas y medidas conceptualmente solapadas. Sobre esa base se construyó un flujo reproducible compuesto por tres piezas principales. En primer lugar, `depurar_tabla.py`, encargado de generar la tabla depurada final. En segundo lugar, `correlaciones.py`, utilizado como script de apoyo para calcular correlaciones, pesos relativos y otras comprobaciones cuantitativas. En tercer lugar, un único fichero acumulativo, `reporte_correlaciones.csv`, que deja constancia de los resultados utilizados para respaldar las decisiones adoptadas.

4.2.1. Criterios generales de depuración

La reducción de la tabla se apoyó en cuatro reglas operativas:

- sustituir recuentos absolutos por porcentajes, tasas por población o densidades por superficie cuando ello mejoraba la comparación territorial;
- conservar una sola variable cuando varias columnas medían prácticamente el mismo fenómeno;
- fusionar subcategorías cuando describían una misma dimensión sustantiva;
- registrar las decisiones en código y en un fichero auxiliar de apoyo metodológico.

Estas reglas se aplicaron de forma sistemática, aunque no mecánica. La selección no se basó en un único umbral estadístico, sino en la combinación de tres tipos de evidencia: redundancia exacta, solapamiento estadístico e interpretabilidad sustantiva.

4.2.2. Eliminación de variables redundantes

Una primera operación consistió en eliminar columnas redundantes o menos adecuadas que otras disponibles. Esto ocurrió, por ejemplo, cuando coexistían variables equivalentes procedentes de distintas fuentes temporales, cuando se conservaban simultáneamente totales y subcategorías completamente derivables, o cuando un mismo fenómeno aparecía expresado como recuento absoluto, porcentaje y densidad sin necesidad de mantener las tres versiones.

El procedimiento se formalizó mediante listas explícitas de columnas a eliminar. De este modo, la depuración no quedó descrita de forma vaga, sino implementada en una secuencia reproducible.

Listing 4.28: Ejemplo de eliminación explícita de columnas duplicadas o redundantes en `depurar_tabla.py`

```
1 DEMOGRAFIA_DROP_COLS = [  
2     "Densitat de població [2025]",  
3     "Edat mitjana [2025]",  
4     "Població resident [2025]",  
5     "INE 2023 demograficos | Porcentaje de hogares unipersonales [dif Valencia]",  
6     "INE 2023 demograficos | Edad media de la población [distrito]",
```

```
7
8     "INE 2023 demograficos | Población [dif Valencia]",
9     "Poblacion distrito [anuario 2021]",
10    "Encuesta demografica 2024 | Esperanza de vida al nacimiento [total]",
11    "Encuesta demografica 2025 | Edad media [total]",
12    "Padron 2024 | Poblacion",
13    "Padron 2025 | Variacion interanual poblacion [%]",
14 ]
15
16 REPLACEMENT_GROUPS = [
17     ("demografia", DEMOGRAFIA_DROP_COLS, NEW_DEMOGRAFIA_COLS),
18 ]
```

Listing 4.29: Lógica exacta de exclusión de columnas en la salida final

```
1 def build_output_columns(original_columns: list[str]) -> list[str]:
2     normalized_groups = [
3         (name, {normalize_text(col) for col in drop_cols}, new_cols)
4         for name, drop_cols, new_cols in REPLACEMENT_GROUPS
5     ]
6
7     output_columns: list[str] = []
8     inserted_groups: set[str] = set()
9
10    for column in original_columns:
11        normalized_column = normalize_text(column)
12        matched = False
13
14        for group_name, drop_set, new_cols in normalized_groups:
15            if normalized_column in drop_set:
16                if new_cols and group_name not in inserted_groups:
17                    output_columns.extend(new_cols)
18                    inserted_groups.add(group_name)
19                    matched = True
20                    break
21
22        if not matched:
23            output_columns.append(column)
```

```
24  
25     return output_columns
```

Este tipo de operación fue particularmente útil en bloques como demografía que contenía variables de fuentes diversas. La lógica seguida fue siempre la misma: si una variable era claramente menos interpretable, más antigua, derivable a partir de otra o duplicaba una dimensión ya bien representada, se eliminaba.

4.2.3. Unificación y agregación de variables

La segunda operación fundamental consistió en unificar varias variables en un único indicador sintético. Esta unificación adoptó tres formas principales: medias simples, sumas de subcategorías y construcción de índices.

Un primer ejemplo es la participación electoral. En lugar de conservar por separado las tasas de participación de varias convocatorias, se construyó una medida media de participación electoral por distrito. Esta decisión se apoyó en la elevada semejanza territorial entre elecciones distintas.

Listing 4.30: Agregación real de la participación electoral en `depurar_tabla.py`

```
1 participation_cols = [  
2     "% Participacio a les Eleccions Autonomiques [2023]",  
3     "% Participacio a les Eleccions Europees [2024]",  
4     "% Participacio a les Eleccions Generals [2023]",  
5     "% Participacio a les Eleccions Locals [2023]",  
6 ]  
7  
8 politics_new = [  
9     "Politica - Participacion electoral media [%]",  
10    "Politica - Votos nulos media [% votos emitidos]",  
11    "Politica - Votos en blanco media [% votos validos]",  
12    "Politica - Votos a candidaturas media [% votos validos]",  
13    "Politica - PP [% votos candidaturas media]",  
14    "Politica - PSOE [% votos candidaturas media]",  
15    "Politica - Compromis Sumar [% votos candidaturas media]",  
16    "Politica - VOX [% votos candidaturas media]",  
17    "Politica - Podemos Unides [% votos candidaturas media]",  
18    "Politica - Ciudadanos [% votos candidaturas media]",
```

```
19     "Politica - Se Acabo La Fiesta [% votos candidaturas media]",
20     "Politica - Otros partidos [% votos candidaturas media]",
21     "Politica - Bloque izquierda PSOE_Compromis_Podemos [% votos candidaturas
media]",
22     "Politica - Bloque derecha PP_VOX-Cs_SALF [% votos candidaturas media]",
23 ]
24
25 for idx, row in reduced_df.loc[non_category_mask].iterrows():
26     participation_values: list[float | None] = []
27     nulos_pct_values: list[float | None] = []
28     blancos_pct_values: list[float | None] = []
29     candidaturas_pct_values: list[float | None] = []
30
31     for spec in specs.values():
32         participation_values.append(row_number(row, spec["part"]))
33         read = row_number(row, spec.get("read", ""))
34         nulos = row_number(row, spec.get("nulos", ""))
35         blancos = row_number(row, spec.get("blanco", ""))
36         candidaturas = row_number(row, spec.get("candidaturas", "")) if spec.get(
"candidaturas") else None
37         validos = row_number(row, spec.get("validos", "")) if spec.get("validos")
else None
38
39         nulos_pct_values.append(pct(nulos, read))
40         blancos_pct_values.append(pct(blancos, validos))
41         candidaturas_pct_values.append(pct(candidaturas, validos))
42
43     values_by_column = {
44         politics_new[0]: mean_non_null(participation_values),
45         politics_new[1]: mean_non_null(nulos_pct_values),
46         politics_new[2]: mean_non_null(blancos_pct_values),
47         politics_new[3]: mean_non_null(candidaturas_pct_values),
48     }
```

Un segundo ejemplo es el bloque de hechos discriminatorios. En este caso, no se trató de calcular una media, sino de reagrupar subcategorías dispersas en dimensiones más legibles desde el punto de vista sustantivo. En el script de depuración, esta agregación se

realiza mediante sumas auxiliares por fila y su posterior incorporación a la tabla final ya normalizadas por población.

Listing 4.31: Agregación real del bloque de hechos discriminatorios en `depurar_tabla.py`

```
1 for _, row in df.iterrows():
2     out_row: dict[str, str] = {}
3     category_row = str(row[codigo_col]) == "__categoria__"
4     population = row[poblacion_col]
5
6     etnico_racial = sum(
7         safe_num(row[col])
8         for col in [racismo_col, romafobia_col, antisemitismo_col,
9                     lengua_cultura_col]
10    )
11    intolerancia_religiosa = sum(
12        safe_num(row[col])
13        for col in [religion_col, islamofobia_col]
14    )
15    capacitismo = sum(
16        safe_num(row[col])
17        for col in [disfobia_col, malalties_col]
18    )
19    sexo_genero_div = sum(
20        safe_num(row[col])
21        for col in [genero_col, lgtbi_col]
22    )
23    values_by_column = {
24        "Hechos discriminatorios [por_1000_hab]":
25            rate_per_1000(row[hechos_total_col], population),
26        "Hechos discriminatorios - Discriminación étnico-cultural y racial [
27        por_1000_hab]":
28            rate_per_1000(etnico_racial, population),
29        "Hechos discriminatorios - Intolerancia religiosa [por_1000_hab]":
30            rate_per_1000(intolerancia_religiosa, population),
31        "Hechos discriminatorios - Capacitismo [por_1000_hab]":
32            rate_per_1000(capacitismo, population),
33        "Hechos discriminatorios - Discriminación por sexo-género y diversidad
```

```
33     sexual [por_1000_hab]":  
34         rate_per_1000(sexo_genero_div, population),  
    }
```

Un tercer tipo de unificación consistió en construir índices sintéticos a partir de variables estrechamente relacionadas, pero expresadas en escalas distintas. En estos casos no se recurrió a una suma directa, sino a una estandarización previa mediante puntuaciones típicas. Este procedimiento se aplicó, por ejemplo, a PM10 y PM2.5 para construir un índice conjunto de contaminación por partículas.

Listing 4.32: Construcción de un índice sintético de partículas en `depurar_tabla.py`

```
1 def z_score(value: float | None, mean_value: float, std_value: float) -> float |  
   None:  
2     if value is None or pd.isna(value) or std_value == 0 or pd.isna(std_value):  
3         return None  
4     return (float(value) - mean_value) / std_value  
5  
6 pm10_mean = df.loc[non_category_mask, contaminacion_pm10_col].mean()  
7 pm10_std = df.loc[non_category_mask, contaminacion_pm10_col].std(ddof=0)  
8 pm25_mean = df.loc[non_category_mask, contaminacion_pm25_col].mean()  
9 pm25_std = df.loc[non_category_mask, contaminacion_pm25_col].std(ddof=0)  
10  
11 particulas_index_by_row: dict[int, float | None] = {}  
12 for idx, source_row in df.iterrows():  
13     z_values = [  
14         z_score(source_row[contaminacion_pm10_col], pm10_mean, pm10_std),  
15         z_score(source_row[contaminacion_pm25_col], pm25_mean, pm25_std),  
16     ]  
17     valid_z_values = [  
18         value for value in z_values  
19         if value is not None and not pd.isna(value)  
20     ]  
21     particulas_index_by_row[idx] = mean_non_null(valid_z_values)
```

La misma lógica se aplicó en otros bloques. En policía local, las categorías operativas se reagruparon en cuatro bloques funcionales; en bomberos, en dos bloques principales; en movilidad, distintos tipos de aparcamiento se reorganizaron en dimensiones de uso

público o privado; y en contaminación atmosférica, variables estrechamente relacionadas se integraron en indicadores más sintéticos y manejables para el análisis posterior.

4.2.4. Normalización y cambio de unidades

La tercera operación fue la formalización a unidades más comparables. En la tabla original coexistían variables expresadas como recuentos absolutos, porcentajes, densidades espaciales o medidas medias. Para evitar que el tamaño poblacional o superficial dominara artificialmente el análisis, se adoptaron unidades homogéneas según la naturaleza del fenómeno.

Se emplearon tasas por cada 1000 habitantes para variables cuya intensidad dependía del número de residentes. Este fue el caso, entre otros, de hechos discriminatorios, asociaciones, recursos sociales, actividad económica, plazas turísticas, aparcamientos o servicios policiales. Se utilizaron tasas por cada 100 habitantes en algunos indicadores urbanos de menor magnitud relativa, y densidades por km^2 cuando la interpretación principal era territorial, como en paradas EMT, itinerarios ciclistas, hidrantes, puntos de alumbrado o equipamientos distribuidos en el espacio.

Listing 4.33: Funciones auxiliares de normalización utilizadas en `depurar_tabla.py`

```
1 import numpy as np
2 import pandas as pd
3
4 def pct(part, total):
5     if pd.isna(part) or pd.isna(total) or total == 0:
6         return np.nan
7     return (part / total) * 100
8
9 def rate_per_1000(part, population):
10     if pd.isna(part) or pd.isna(population) or population == 0:
11         return np.nan
12     return (part / population) * 1000
13
14 def rate_per_100(part, population):
15     if pd.isna(part) or pd.isna(population) or population == 0:
16         return np.nan
17     return (part / population) * 100
18
```

```
19 def rate_per_km2(value, area_km2):  
20     if pd.isna(value) or pd.isna(area_km2) or area_km2 == 0:  
21         return np.nan  
22     return value / area_km2
```

La decisión sobre qué unidad aplicar no fue arbitraria. Se consideró que las tasas poblacionales eran más adecuadas cuando interesaba medir intensidad relativa sobre residentes, mientras que las densidades por superficie eran preferibles cuando se trataba de infraestructuras, coberturas o presiones territoriales.

Un ejemplo claro de esta formalización aparece en policía local y bomberos. Las columnas originales de servicios absolutos se sustituyeron por tasas por 1000 habitantes, calculadas a partir de la población del Padrón 2025.

Listing 4.34: Ejemplo de transformación a tasas comparables

```
1 output["Policia local - Trafico y movilidad [por_1000_hab]"] = df.apply(  
2     lambda r: rate_per_1000(  
3         r["Recursos municipales 2024 policia local | Servicios trafico [n]"],  
4         r["Padron 2025 | Poblacion"]  
5     ),  
6     axis=1  
7 )  
8  
9 output["Bomberos - Rescate y asistencia [por_1000_hab]"] = df.apply(  
10     lambda r: rate_per_1000(  
11         r["Recursos municipales 2024 bomberos | Salvamentos [n]"]  
12         + r["Recursos municipales 2024 bomberos | Asistencia tecnica [n]"],  
13         r["Padron 2025 | Poblacion"]  
14     ),  
15     axis=1  
16 )
```

4.2.5. Apoyo cuantitativo a las decisiones metodológicas

Esta subsección recoge cómo se empleó el análisis de correlaciones como criterio de contraste en el proceso de depuración y reducción de variables. Las decisiones primero se plantearon desde una lectura lógica del significado de las variables, de su pertenencia temática y de su utilidad analítica dentro de cada bloque. Posteriormente, se recurrió a

las correlaciones para valorar si esa decisión era coherente con la estructura empírica de los datos.

Para ello se utilizó el script `correlaciones.py`, concebido como herramienta de apoyo manual. Su lógica es deliberadamente simple: se definen listas editables de pares de variables o de componentes de un mismo bloque, se ejecuta el cálculo y se vuelcan los resultados en un único fichero acumulativo, `reporte_correlaciones.csv`.

Listing 4.35: Esquema base de `correlaciones.py`

```
1 PAIR_CHECKS = [  
2     {  
3         "bloque": "Economia",  
4         "variable_1": "INE - Renta media por persona [EUR distrito]",  
5         "variable_2": "INE - Renta media por hogar [EUR distrito]",  
6         "decision_metodologica": (  
7             "Rentas por persona y por hogar presentan solapamiento; "  
8             "se conserva renta por persona como indicador principal."  
9         ),  
10    },  
11    {  
12        "bloque": "Educacion - PAU",  
13        "variable_1": (  
14            "Educacion | Resultados de Bachillerato y notas PAU por distrito. "  
15            "Curso 202425 | Alumnado matriculado"  
16        ),  
17        "variable_2": (  
18            "Educacion | Resultados de Bachillerato y notas PAU por distrito. "  
19            "Curso 202425 | Alumnado presentado"  
20        ),  
21        "decision_metodologica": (  
22            "No se conserva el recuento absoluto de presentados; "  
23            "se transforma en porcentaje sobre alumnado matriculado."  
24        ),  
25    },  
26 ]  
27  
28 def add_corr(df, non_category_mask, block, col_a, col_b, decision):  
29     pair_df = df.loc[non_category_mask, [col_a, col_b]].copy()
```

```
30 pair_df[col_a] = pd.to_numeric(pair_df[col_a], errors="coerce")
31 pair_df[col_b] = pd.to_numeric(pair_df[col_b], errors="coerce")
32 pair_df = pair_df.dropna()
33
34 corr_value = None if len(pair_df) < 2 else float(pair_df[col_a].corr(pair_df[
col_b]))
35
36 return {
37     "bloque": block,
38     "tipo_medida": "correlacion_pearson",
39     "variable_1": col_a,
40     "variable_2": col_b,
41     "valor": corr_value,
42     "n_observaciones": len(pair_df),
43     "decision_metodologica": decision,
44 }
```

Además de correlaciones de Pearson, también se registraron pesos relativos sobre el total del bloque cuando la cuestión no era tanto medir solapamiento lineal como justificar una reagregación temática. Esto ocurrió, por ejemplo, en policía local y bomberos.

En la versión entregada, `reporte_correlaciones.csv` reúne en un solo fichero el histórico consolidado de correlaciones documentadas a lo largo del proceso y las comprobaciones manuales actuales. Por tanto, no se trata únicamente de un reporte final, sino de una pieza de auditoría metodológica del procedimiento.

La Tabla 4.1 resume algunos ejemplos especialmente representativos.

Tabla 4.1: Ejemplos de decisiones respaldadas por evidencia cuantitativa

Bloque	Decisión metodológica	Evidencia de apoyo
Política	Sustituir varias convocatorias por una participación electoral media	Correlaciones entre elecciones entre 0,961 y 0,997; correlación de cada elección con la media entre 0,984 y 0,999
Economía	Reducir medidas medias de renta	$r = 0,973$ entre renta por persona y renta por hogar; $r = 0,996$ entre renta por persona y renta por unidad de consumo
Medio ambiente	Eliminar NO y NOx y conservar NO ₂	$r = 0,998$ entre NO y NOx; $r = 0,994$ entre NO ₂ y NOx; $r = 0,985$ entre NO y NO ₂
Medio ambiente	Integrar PM10 y PM2.5 en un único índice	$r = 0,749$ entre PM10 y PM2.5
Educación	Sustituir recuentos absolutos de PAU por proporciones	$r = 1,000$ entre matriculado y presentado; $r = 0,998$ entre presentado y apto
Urbanismo	Evitar duplicar parcelas urbanas y solares	$r = 1,000$ entre parcelas urbanas totales y número de solares
Seguridad	Reagrupar servicios de policía local	Peso relativo de tráfico 23,420 %, seguridad ciudadana 18,882 % y vigilancias 15,047 %

4.2.6. Resultado final de la depuración

El resultado de esta fase fue una reducción de 978 a 260 columnas, manteniendo una estructura más legible y adecuada para el análisis multivariante posterior. La salida principal generada por `depurar_tabla.py` es `tabla_por_distritos_final_depurada.csv`. Esta tabla no constituye todavía el análisis multivariante final, pero sí la matriz analítica sobre la que se aplicarán técnicas multivariantes.

En consecuencia, la depuración no debe entenderse como una simple limpieza técnica, sino como una etapa de construcción metodológica. Su función fue transformar una base de datos integrada, pero todavía muy descriptiva, en una matriz defendible desde el punto de vista analítico.

4.3. Jerarquización de la matriz

Una vez depurada la tabla, se llevó a cabo una segunda fase orientada no ya a transformar valores, sino a organizar conceptualmente la matriz resultante. Esta etapa se implementó mediante el script `jerarquizar_tabla.py`, cuya función es clasificar cada variable final según bloque temático, subdimensión y rol analítico.

La jerarquización responde a dos necesidades. En primer lugar, mejora la legibilidad del conjunto de indicadores. En segundo lugar, permite distinguir entre variables activas, variables suplementarias y variables auxiliares, de modo que el análisis multivariante posterior no se aplique de forma indiscriminada sobre todas las columnas.

4.3.1. Bloques temáticos y subdimensiones

La matriz final se organizó en bloques temáticos amplios: urbanismo e infraestructuras, movilidad y transporte, política, economía, demografía, sociedad y bienestar, educación, medio ambiente, seguridad y convivencia, además de identificación y variables auxiliares. Dentro de cada bloque se definieron subdimensiones más específicas, como renta y desigualdad, estructura por edad, tejido asociativo, contaminación atmosférica, resultados PAU o policía local.

Esta organización no se introdujo únicamente con fines expositivos. También facilita la interpretación de componentes principales o agrupamientos posteriores, al permitir identificar con mayor claridad qué dimensiones sustantivas están contribuyendo a la diferenciación territorial entre distritos.

4.3.2. Roles analíticos de las variables

Además del bloque temático y la subdimensión, cada variable se clasificó según su rol en el análisis. Se distinguieron cinco categorías:

- variables de identificación, como `codigo` y `nombre`;
- variables auxiliares, utilizadas como denominadores o referencias técnicas;
- variables suplementarias contextuales;
- variables suplementarias interpretativas;
- variables activas candidatas para PCA o clustering.

Esta clasificación resulta especialmente útil porque no todas las variables tienen la misma función metodológica. Algunas son adecuadas para entrar directamente en el análisis factorial o de agrupamiento, mientras que otras son más útiles para interpretar después los resultados obtenidos.

Listing 4.36: Asignación de metadatos jerárquicos en `jerarquizar_tabla.py`

```
1 dictionary.append({  
2     "orden": i + 1,  
3     "variable": col,  
4     "bloque_tematico": block,  
5     "subdimension": subdim,  
6     "rol_analisis": role,  
7     "nota_uso": explain_role(role),  
8 })
```

Para el ajuste multivariante no se empleó la matriz completa de forma indiscriminada. A partir de la tabla jerarquizada se tomó como punto de partida el conjunto de variables activas candidatas, excluyendo las columnas de identificación, las variables auxiliares y las variables suplementarias. Las variables de identificación, como el código y el nombre del distrito, se conservaron únicamente como referencia externa; las variables auxiliares se utilizaron como apoyo técnico en la construcción de tasas o densidades; y las variables suplementarias se reservaron para la interpretación posterior de los perfiles obtenidos.

En la versión final, la tabla distingue 243 variables activas candidatas. De ellas, la solución principal del modelo emplea 219 variables activas numéricas con cobertura completa

entre los 19 distritos. Esta decisión permite mantener una matriz de análisis comparable, evita introducir imputaciones en el ajuste principal y reduce el riesgo de que variables incompletas, etiquetas territoriales o denominadores técnicos condicionen artificialmente la geometría del modelo. Las variables con valores perdidos se mantienen como referencia para comprobaciones complementarias, pero no como base principal de la partición.

4.3.3. Productos finales de la jerarquización

La salida de esta fase no es solo una tabla más ordenada, sino un pequeño sistema documental asociado a la matriz final. A partir de `jerarquizar_tabla.py` se generan los siguientes ficheros:

- `tabla_por_distritos_final_jerarquizada.csv`,
- `diccionario_jerarquia_variables_final.csv`,
- `resumen_jerarquia_bloques_final.csv`.

La tabla jerarquizada conserva la fila temática y añade nuevas filas de metadatos con subdimensión y rol analítico. El diccionario resume cada variable en formato largo, mientras que el resumen por bloques permite conocer cuántas variables pertenecen a cada dimensión y cuántas de ellas son candidatas activas o suplementarias.

Listing 4.37: Generación de filas de metadatos jerárquicos

```
1 metadata_rows = [  
2     categories,  
3     [  
4         "__subdimension__" if c == "codigo"  
5         else "SUBDIMENSION" if c == "nombre"  
6         else subdims[i]  
7         for i, c in enumerate(headers)  
8     ],  
9     [  
10        "__rol_analisis__" if c == "codigo"  
11        else "ROL_ANALISIS" if c == "nombre"  
12        else roles[i]  
13        for i, c in enumerate(headers)  
14    ],
```

4.4. Visualización interactiva de la tabla distrital

Una vez obtenida la tabla depurada y jerarquizada, se generó una visualización interactiva por distritos con el objetivo de facilitar la exploración territorial de los indicadores finales, permitir una inspección visual preliminar de la distribución espacial de las variables y ofrecer una herramienta de consulta más accesible sobre la matriz final.

Para ello se empleó el script `generar_mapa_interactivo_v31_v32.py`, que construye un fichero HTML autocontenido a partir de tres entradas: la tabla distrital integrada, el diccionario jerárquico de variables y el fichero territorial de los distritos. El resultado es el mapa `mapa_interactivo_distritos_v31_jerarquizado.html`, en el que cada distrito puede visualizarse dinámicamente según la variable seleccionada.

4.4.1. Lectura de datos y selección de variables numéricas

El primer paso consistió en cargar la tabla por distritos y el diccionario jerárquico de variables. La tabla aporta los valores de cada indicador por distrito, mientras que el diccionario añade información interpretativa sobre bloque temático, subdimensión y rol analítico. A partir de la tabla se separó la fila especial de categorías y se conservaron únicamente las filas correspondientes a distritos reales.

Listing 4.38: Lectura de la tabla y del diccionario jerárquico

```
1 def load_table() -> tuple[dict[str, str], list[dict[str, str]]:
2     with INPUT_CSV.open("r", encoding="utf-8-sig", newline="") as handle:
3         reader = csv.DictReader(handle)
4         rows = list(reader)
5
6         category_row = next((row for row in rows if row.get("codigo") == "
7         __categoria__"), {})
8         district_rows = [row for row in rows if row.get("codigo") and row["codigo"]
9         != "__categoria__"]
10        return category_row, district_rows
11
12 def load_hierarchy() -> dict[str, dict[str, str]]:
```

```
12 with HIERARCHY_CSV.open("r", encoding="utf-8-sig", newline="") as handle:
13     reader = csv.DictReader(handle)
14     return {row["variable"]: row for row in reader}
```

Una vez cargada la tabla, el script identificó qué columnas eran realmente representables en el mapa. Para ello se descartaron `codigo` y `nombre`, y se comprobó si cada columna contenía al menos un valor convertible a número en alguna fila. Este filtrado permitió limitar la visualización a indicadores cuantitativos, evitando incluir columnas textuales o de control.

Listing 4.39: Identificación de variables numéricas cartografiables

```
1 def infer_numeric_variables(rows: list[dict[str, str]], ordered_columns: list[str]
  ) -> list[str]:
2     numeric: list[str] = []
3     for column in ordered_columns:
4         if column in {"codigo", "nombre"}:
5             continue
6         if any(parse_number(row.get(column)) is not None for row in rows):
7             numeric.append(column)
8     return numeric
```

4.4.2. Construcción de la geometría distrital

El segundo paso consistió en reconstruir la geometría de los distritos a partir del fichero territorial. El script parte de un archivo comprimido con estructura KML, extrae los `Placemark`, identifica el código de distrito en la descripción asociada y transforma las coordenadas en una estructura *GeoJSON* compatible con la representación web.

Listing 4.40: Conversión del fichero territorial a GeoJSON

```
1 def build_geojson_from_kmz(path: Path) -> dict:
2     kml_text = load_kml_from_kmz(path)
3     root = ET.fromstring(kml_text)
4     placemarks = root.findall("://{*}Placemark")
5
6     grouped: OrderedDict[str, dict[str, object]] = OrderedDict()
7
8     for placemark in placemarks:
```

```
9     name = (placemark.findtext("{*}name") or "").strip()
10    description = placemark.findtext("{*}description") or ""
11    code = extract_district_code(description)
12    if not code:
13        continue
14
15    polygons: list[list[list[float]]] = []
16    for polygon in placemark.findall("./{*}Polygon"):
17        coord_text = polygon.findtext("./{*}outerBoundaryIs/{*}LinearRing
18    /*{*}coordinates")
19        if not coord_text:
20            continue
21        ring = parse_coordinates(coord_text)
22        if ring:
23            polygons.append(ring)
24
25    if not polygons:
26        continue
27
28    if code not in grouped:
29        grouped[code] = {"code": code, "name": name, "polygons": []}
30
31    grouped[code]["polygons"].extend(polygons)
```

Posteriormente, el script calculó la envolvente geográfica total del conjunto de distritos. Esta operación permitió ajustar automáticamente el encuadre inicial del mapa para que toda la ciudad apareciera visible al abrir la visualización.

4.4.3. Integración de metadatos jerárquicos

El tercer paso consistió en vincular cada variable numérica con sus metadatos jerárquicos. Para cada columna cartografiable se recuperó, siempre que estuviera disponible, su categoría original, bloque temático, subdimensión, rol analítico y nota de uso. De este modo, la visualización no solo representa valores, sino que conserva la estructura conceptual de la matriz final.

Listing 4.41: Construcción de metadatos para las variables del mapa

```
1 def build_variable_metadata(  
2     columns: list[str],  
3     numeric_variables: list[str],  
4     category_row: dict[str, str],  
5     hierarchy: dict[str, dict[str, str]],  
6 ) -> list[dict[str, str]]:  
7     numeric_set = set(numeric_variables)  
8     metadata: list[dict[str, str]] = []  
9  
10    for column in columns:  
11        if column not in numeric_set:  
12            continue  
13        row = hierarchy.get(column, {})  
14        metadata.append(  
15            {  
16                "variable": column,  
17                "categoria_original": category_row.get(column, "Sin categoria"),  
18                "bloque_tematico": row.get("bloque_tematico", category_row.get(  
19                    column, "Sin bloque")),  
20                "subdimension": row.get("subdimension", "Sin subdimension"),  
21                "rol_analisis": row.get("rol_analisis", "Sin jerarquia"),  
22                "nota_uso": row.get("nota_uso", ""),  
23            }  
24        )  
25    return metadata
```

4.4.4. Generación del documento HTML

La visualización final se construyó como un único documento HTML autocontenido. Para ello, el script convierte a JSON tanto los datos tabulares como la geometría y los metadatos, y los inserta directamente en el documento. Esta solución evita dependencias externas de lectura de ficheros en tiempo de ejecución y facilita la portabilidad del mapa.

Listing 4.42: Inserción de datos y geometría en el documento HTML

```
1 def build_html(  
2     rows: list[dict[str, str]],
```

```
3     variable_metadata: list[dict[str, str]],
4     district_geojson: dict,
5     initial_bounds: list[list[float]],
6 ) -> str:
7     data_json = json.dumps(rows, ensure_ascii=False)
8     variables_json = json.dumps(variable_metadata, ensure_ascii=False)
9     geojson_json = json.dumps(district_geojson, ensure_ascii=False)
10    bounds_json = json.dumps(initial_bounds, ensure_ascii=False)
11
12    return f"""<!DOCTYPE html>
13<html lang="es">
14...
15<script id="district-data" type="application/json">{data_json}</script>
16<script id="variable-metadata" type="application/json">{variables_json}</script>
17<script id="district-geojson" type="application/json">{geojson_json}</script>
18<script id="initial-bounds" type="application/json">{bounds_json}</script>
19...
20</html>
21"""
```

En la parte cliente, el documento HTML incorpora una interfaz con filtros por categoría temática, rol analítico y búsqueda textual de variables. Además, el mapa aplica una escala de color continua sobre los distritos y muestra ventanas emergentes con el nombre del distrito y el valor del indicador seleccionado.

4.4.5. Escritura del mapa y flujo principal

Finalmente, el script escribe el fichero HTML resultante en la misma carpeta de trabajo del mapa. El flujo completo queda resumido en la función principal:

Listing 4.43: Flujo principal de generación del mapa interactivo

```
1 def main() -> None:
2     category_row, rows = load_table()
3     hierarchy = load_hierarchy()
4     ordered_columns = list(category_row.keys()) if category_row else list(rows
5     [0].keys())
6     numeric_variables = infer_numeric_variables(rows, ordered_columns)
```

```
6     variable_metadata = build_variable_metadata(  
7         ordered_columns, numeric_variables, category_row, hierarchy  
8     )  
9     district_geojson = build_geojson_from_kmz(KMZ_PATH)  
10    initial_bounds = compute_bounds(district_geojson)  
11  
12    HTML_OUTPUT.write_text(  
13        build_html(rows, variable_metadata, district_geojson, initial_bounds),  
14        encoding="utf-8",  
15    )
```

La visualización resultante permite seleccionar variables por nombre, filtrar por categoría temática y rol analítico, consultar metadatos explicativos y observar la distribución espacial de cada indicador mediante una escala de color continua. Además, el mapa muestra estadísticas básicas de la variable activa, como mínimo, máximo, media y número de distritos con dato disponible.

Desde un punto de vista metodológico, esta fase no constituye un análisis estadístico independiente, pero sí una herramienta de validación exploratoria y de comunicación de resultados. Por un lado, facilita detectar patrones espaciales evidentes antes del análisis multivariante formal. Por otro, ofrece una forma intuitiva de consultar la tabla final sin necesidad de revisar manualmente el CSV completo. En este sentido, el mapa interactivo actúa como puente entre la matriz depurada y la interpretación territorial posterior de los distritos de Valencia.

Puede consultarse en el siguiente enlace: [Mapa interactivo de distritos](#).

4.5. Descripción del modelo

4.5.1. Justificación metodológica del modelo

El objetivo del clustering en este trabajo no es predecir una variable objetivo conocida, sino identificar perfiles territoriales latentes a partir de una matriz distrital compuesta por indicadores demográficos, económicos, residenciales, ambientales, de movilidad y de dotación de servicios. Por ello, el problema se sitúa en el ámbito del aprendizaje no supervisado. A diferencia del aprendizaje supervisado, donde se dispone de una etiqueta previa y el modelo aprende una función de predicción, en clustering no existe una clase verdadera

conocida de antemano: la agrupación se obtiene a partir de la similitud entre observaciones en el espacio de variables.

Este enfoque resulta adecuado para el estudio de la desigualdad urbana porque permite sintetizar una gran cantidad de información en un número reducido de perfiles distritales interpretables. En lugar de analizar cada indicador por separado, el clustering capta configuraciones conjuntas de renta, densidad, actividad económica, estructura residencial, movilidad o vulnerabilidad, lo que facilita una lectura territorial más integrada.

Se seleccionó el algoritmo *K-Means* por tres razones principales. En primer lugar, por su interpretabilidad: cada grupo queda representado por un centroide, es decir, por un perfil medio claramente describible. En segundo lugar, por su adecuación a una muestra pequeña de observaciones ($n = 19$ distritos), donde un método de particionado simple y estable resulta metodológicamente más defendible que modelos más complejos. En tercer lugar, por su facilidad de representación territorial, ya que permite asociar cada distrito a un grupo definido por promedios multivariantes y discutir después sus características urbanas.

Frente a otras alternativas, *K-Means* ofrece un equilibrio razonable entre simplicidad, estabilidad y legibilidad. DBSCAN es útil cuando existen densidades locales bien definidas y suficientes observaciones para estimar vecindades robustas, pero su comportamiento es más sensible a los parámetros de densidad y no resulta tan natural con solo 19 distritos. El clustering jerárquico aporta un dendrograma útil para exploración, aunque puede variar según el criterio de enlace y no siempre produce particiones finales fáciles de resumir mediante centroides. Los modelos de mezclas gaussianas permiten fronteras probabilísticas más flexibles, pero introducen una parametrización adicional más difícil de sostener con una muestra pequeña y con variables procedentes de fuentes heterogéneas. En consecuencia, *K-Means* se consideró la opción más parsimoniosa para una primera tipología distrital interpretable.

Desde el punto de vista matemático, *K-Means* busca la partición que minimiza la suma de cuadrados intra-cluster:

$$\min_{C_1, \dots, C_k} \sum_{r=1}^k \sum_{x_i \in C_r} \|x_i - \mu_r\|_2^2,$$

donde μ_r es el centroide del cluster r , definido como la media vectorial de las observaciones asignadas a dicho grupo:

$$\mu_r = \frac{1}{|C_r|} \sum_{x_i \in C_r} x_i.$$

La distancia empleada es la euclídea, por lo que dos distritos serán similares si presentan valores próximos en el conjunto de variables activas. La magnitud que resume el ajuste es la inercia, entendida como la suma total de distancias cuadráticas entre cada observación y el centroide de su cluster. Cuanto menor es la inercia, menor es la dispersión interna de los grupos.

La selección de $k = 4$ se justificó mediante una combinación de criterio estadístico e interpretabilidad territorial. El método del codo muestra que, a partir de cuatro grupos, la reducción adicional de la inercia deja de ser tan marcada, por lo que aumentar k aporta un rendimiento decreciente. Además, la solución con cuatro clusters ofrece una lectura urbana clara: un grupo amplio de distritos intermedios y densos, un cluster singular asociado a Ciutat Vella, un cluster central acomodado en torno a L'Eixample y un grupo periférico-extensivo representado por Poblets del Sud.

4.5.2. Preparación y escalado de los datos

Antes de aplicar el clustering, se transformó la matriz distrital final a un formato utilizable por el modelo. Para ello, se conservaron los nombres de distrito como identificadores externos, se excluyeron del espacio activo las variables no numéricas y se trabajó únicamente con columnas cuantitativas comparables. Esta preparación evita que el algoritmo procese simultáneamente etiquetas territoriales y variables explicativas, lo que distorsionaría la geometría del problema.

El escalado se realizó mediante una transformación *MinMax*. Esta decisión era necesaria porque la matriz integra variables medidas en escalas muy diferentes: porcentajes, tasas por población, densidades por superficie, valores monetarios y magnitudes ambientales. Sin normalización, las variables con mayor rango numérico dominarían la distancia euclídea y, por tanto, la construcción de clusters. La transformación aplicada fue:

$$x'_{ij} = \frac{x_{ij} - \min(x_j)}{\max(x_j) - \min(x_j)},$$

donde x_{ij} es el valor original de la variable j en el distrito i y x'_{ij} su valor reescalado al intervalo $[0, 1]$. Este procedimiento preserva el orden relativo entre distritos y evita que la unidad de medida de una sola variable condicione artificialmente la partición final.

4.5.3. Análisis exploratorio mediante PCA

Antes de aplicar e interpretar la partición final, se realizó un análisis de componentes principales (PCA) como comprobación exploratoria de la estructura multivariante de la matriz activa. El PCA no sustituye al clustering, ya que no asigna distritos a grupos, pero permite reducir la dimensionalidad del conjunto de variables y visualizar si existen patrones territoriales coherentes en las primeras componentes.

Matemáticamente, cada componente principal se construye como una combinación lineal de las variables originales:

$$Z_m = \phi_{1m}X_1 + \phi_{2m}X_2 + \cdots + \phi_{pm}X_p,$$

donde Z_m representa la componente principal m , X_j es la variable original j y ϕ_{jm} es la carga o peso de dicha variable en la componente. Para cada componente, el vector de cargas se normaliza habitualmente imponiendo:

$$\sum_{j=1}^p \phi_{jm}^2 = 1.$$

Las componentes se ordenan de mayor a menor varianza explicada, de modo que las primeras resumen la mayor parte de la variabilidad conjunta de la matriz. Dado que las variables originales están medidas en escalas muy diferentes, el PCA se aplicó sobre la matriz previamente reescalada, evitando que las variables con mayor rango numérico dominaran artificialmente la solución.




Figura 4.1: Varianza explicada acumulada por el PCA

La Figura 4.1 muestra que la primera componente explica aproximadamente el 29,0 % de la varianza, la segunda el 13,8 % y la tercera el 11,9 %. En conjunto, las tres primeras componentes acumulan alrededor del 54,7 % de la información, mientras que las ocho primeras alcanzan aproximadamente el 79,9 %. Esto indica que existe una estructura multivariante resumible, aunque no reducible a una única dimensión dominante.

Además de la varianza acumulada, se proyectaron los distritos sobre las dos primeras componentes principales para observar su posición relativa en un espacio bidimensional.




Figura 4.2: Distritos proyectados sobre las dos primeras componentes principales

La Figura 4.2 permite observar que Ciutat Vella aparece claramente separada del resto de distritos, mientras que L'Eixample, Extramurs y El Pla del Real se sitúan próximos entre sí. Los Poblats también ocupan una posición diferenciada respecto a la ciudad compacta. Esta distribución visual es coherente con la solución obtenida mediante K-Means: Ciutat Vella emerge como caso singular, el eje central acomodado forma un perfil propio, y los distritos periféricos-extensivos se separan del bloque urbano intermedio.

Por tanto, el PCA cumple aquí una función exploratoria y de validación visual. No se utiliza para sustituir el modelo de clustering, sino para comprobar que la clasificación final responde a una estructura multivariante interpretable.

4.5.4. Elección del número de clusters

Para determinar el número de clusters se aplicaron tres métodos: el método del codo, calculando la inercia para distintos valores de k ; el valor de silueta, que indica la similitud de cada objeto con el resto de objetos de su propio grupo frente a los de otros grupos; y el índice de Davies-Bouldin, que evalúa la relación entre la dispersión interna de los clusters y la separación entre centroides.




Figura 4.3: Comparación de métricas internas para la elección del número de clusters

La lógica del método del codo consiste en identificar el punto a partir del cual aumentar el número de grupos ya no reduce de forma sustancial la variación intra-cluster. En este caso, la caída más interpretable de la inercia se produce hasta $k = 4$, mientras que valores superiores generan una segmentación más fina pero menos parsimoniosa.

El coeficiente de silueta toma valores entre -1 y 1. Valores próximos a 1 indican observaciones bien asignadas y alejadas de otros grupos; valores próximos a 0 indican observaciones situadas en zonas de frontera; y valores negativos sugieren posibles asignaciones poco adecuadas. En este caso, la silueta es mayor para particiones más simples, lo que resulta esperable en una muestra reducida de 19 distritos. Por ello, no se utilizó como criterio automático de maximización, sino como una medida complementaria.

El índice de Davies-Bouldin compara la dispersión interna de los clusters con la distancia entre sus centroides. Para cada cluster i , se considera su dispersión media S_i , y para cada par de clusters i, j , la distancia M_{ij} entre centroides. El índice se define como:

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right).$$

Valores más bajos indican, en general, clusters más compactos y mejor separados. En

este trabajo, la solución con $k = 4$ ofrece un valor de Davies-Bouldin inferior al obtenido con $k = 3$ y $k = 5$, lo que refuerza su interés como partición interpretable. Aunque $k = 8$ presenta un valor menor, esa solución fragmenta en exceso una muestra de solo 19 distritos y resulta menos defendible desde el punto de vista territorial.

La elección final de $k = 4$ no se apoya solo en los gráficos, sino también en la coherencia sustantiva de la solución. Con cuatro grupos se distinguen perfiles urbanos reconocibles y útiles para el objetivo del trabajo: distritos densos intermedios, centro histórico-turístico, eje central acomodado y periferia extensiva. Esta lectura se vuelve menos precisa con $k = 3$, donde Ciutat Vella pierde singularidad, y más fragmentada con $k = 5$, donde la ciudad se sobresegmenta en grupos pequeños.

4.5.5. Resultado del ajuste con $k = 4$

La solución principal con $k = 4$ genera grupos de tamaños 12, 1, 3 y 3.

En el cluster 0 encontramos los distritos: Campanar, La Saldia, L'Olivereta, Patraix, Jesus, Quatre Carreres, Poblets Maritims, Camins al Grau, Algiros, Benimaclet, Rascanya y Benicalap.

En el cluster 1 encontramos únicamente el distrito Ciutat Vella.

En el cluster 2 encontramos los distritos: L'Eixample, Extramurs y El Pla del Real.

En el cluster 3 encontramos los distritos: Poblets del Nord, Poblets de l'Oest y Poblets del Sud.

Los distritos más próximos a los centroides identificados en el ajuste son Jesús, Ciutat Vella, L'Eixample y Poblets del Sud. Para interpretar mejor esta partición, conviene no quedarse solo con el nombre del distrito representativo, sino observar las medias por cluster en variables sintéticas con alta capacidad descriptiva.

La Tabla 4.2 resume dichas medias para un conjunto de indicadores especialmente útiles para leer desigualdad urbana, estructura económica, presión turística y posición residencial.

Tabla 4.2: Medias por cluster en variables sintéticas seleccionadas

Variable	C0 Jesús	C1 Ciutat Vella	C2 L'Eixample	C3 Poblets del Sud
Densidad de población [hab/km ²]	18737.58	18055.00	23529.67	2974.67
Renta media por persona [EUR]	15056.75	22047.00	22182.00	14549.33
Paro [%]	9.33	6.49	6.11	9.51
Pobreza infantil [%]	28.67	16.30	14.27	28.03
Valor catastral medio [EUR/m ²]	388.08	485.18	538.25	317.14
Actividad económica [por 1000 hab]	122.05	566.73	313.48	180.91
Vivienda turística [% viviendas]	1.53	6.53	1.98	0.59
Hogares unipersonales [%]	34.51	47.50	39.24	30.61
Zonas verdes [m ² /hab]	63.96	39.89	52.66	76.50
Hechos discriminatorios [por 1000 hab]	0.52	2.29	0.67	0.19

También es necesario conocer el ajuste del modelo para poder interpretar los datos, ya que un ajuste débil no permite extraer conclusiones sólidas. Para ello, se revisaron las variables que más se alejaban del centroide de su cluster. En concreto, se consideraron como señales de posible anomalía aquellas distancias situadas en el 5 % superior. Con este criterio, Poblets Maritims aparece como el distrito con mayor número de señales atípicas relativas. Estas señales se distribuyen en 18 variables, cuyas categorías se resumen en la Tabla 4.3.

Tabla 4.3: Anomalías detectadas en la segmentación por clústeres

Categoría	Recuento
Movilidad y Transporte	8
Urbanismo e Infraestructura	6
Demografía	2
Sociedad y Bienestar	2

Este análisis también permite detectar qué dimensiones pesan más en la aparición de valores atípicos dentro de la segmentación. En este caso, la mayoría pertenecen al bloque de movilidad y transporte, que representa casi la mitad de las señales detectadas.

Sabiendo que este tipo de variables tiene una presencia reducida en la base de datos original, la sobrerrepresentación de esta categoría entre las señales atípicas no parece deberse únicamente al número de indicadores disponibles. Por ello, puede interpretarse que estos factores contribuyen de manera relevante a diferenciar algunos distritos dentro de la segmentación.

Otra forma de comprobar el ajuste del modelo es utilizar el valor de silueta. En este caso, el valor obtenido es 0,17, lo que indica que una parte relevante de las observaciones se encuentra próxima a las fronteras entre clusters. Este resultado debe interpretarse teniendo

en cuenta el reducido número de distritos.

Otro método de comprobación es el índice de Davies-Bouldin (DBI). El valor para este modelo es de 1,19, lo que sugiere que la separación entre grupos es moderada y que los clusters deben leerse como perfiles exploratorios, no como clases cerradas.

4.6. Análisis de resultados

4.6.1. Interpretación territorial de los clusters

El cluster 0, representado por Jesús, agrupa el bloque más amplio de la ciudad compacta no central. En él se concentran distritos densos e intermedios, con una densidad media de 18737.58 hab/km², rentas relativamente contenidas (15056.75 EUR por persona), valores de paro y pobreza infantil superiores a los del eje central y una intensidad económica moderada. Este perfil no debe interpretarse de forma simplista como “clase media”, sino como un conjunto de distritos densos y consolidados que ocupan una posición intermedia entre la centralidad económica y la periferia extensiva, y donde aparecen rasgos de vulnerabilidad residencial y laboral.

El cluster 1, formado por Ciutat Vella, constituye el caso más singular del sistema urbano. Destaca por la mayor actividad económica del conjunto (566.73 actividades por 1000 habitantes), el mayor peso de vivienda turística (6.53 %), el mayor porcentaje de hogares unipersonales (47.50 %) y una intensidad especialmente alta de hechos discriminatorios registrados (2.29 por 1000 habitantes). Todo ello, unido a una población extranjera relativamente elevada y a una fuerte centralidad funcional, apunta a un perfil de centro histórico sometido a elevada presión urbana y turística.

El cluster 2, representado por L'Eixample, agrupa distritos centrales de posición socio-económica comparativamente ventajosa. Presenta la renta media por persona más alta del conjunto (22182 EUR), el mayor valor catastral por metro cuadrado (538.25 EUR/m²), un paro contenido (6.11 %) y una densidad alta de actividad económica y servicios. Además, en la matriz amplia aparecen valores destacados en empresas activas, oficinas bancarias, terrazas de hostelería e infraestructura ciclista, lo que refuerza su carácter de centralidad económica consolidada.

El cluster 3, representado por Poblets del Sud, define el perfil periférico-extensivo. Su rasgo más distintivo es la baja densidad de población (2974.67 hab/km²), acompañada de una mayor disponibilidad relativa de zonas verdes y de una estructura territorial mucho

menos compacta. Sin embargo, esta menor densidad no implica necesariamente una posición ventajosa: el cluster combina valores de renta bajos, paro relativamente alto, valor catastral reducido y mayor analfabetismo relativo. Por tanto, se trata de una periferia diferenciada tanto por su estructura espacial como por ciertas fragilidades socioeconómicas.

Para poder comparar con mayor facilidad los distintos clústers, se realizó un análisis de las medias de cada uno de distintas variables como la renta media y la densidad de población.

Tabla 4.4: Variables interpretativas: densidad, renta, paro y pobreza infantil

Clúster	Densidad de población (hab/km ²)	Renta neta media por persona (EUR)	Población parada	Pobreza infantil
0	18737.58	15056.75	9.33	28.67
1	18055.00	22047.00	6.49	16.30
2	23529.67	22182.00	6.11	14.27
3	2974.67	14549.33	9.51	28.03

Tabla 4.5: Variables interpretativas: valor catastral, actividad económica y vivienda turística

Clúster	Valor catastral medio por metro cuadrado (EUR/m ²)	Actividades económicas (por 1000 hab)	Viviendas turísticas
0	388.08	122.05	1.53
1	485.18	566.73	6.53
2	538.25	313.48	1.98
3	317.14	180.91	0.59

Tabla 4.6: Variables interpretativas: hogares unipersonales, zonas verdes y hechos discriminatorios

Clúster	Hogares unipersonales	Superficie zonas verdes (m ² /hab)	Hechos discriminatorios (por 1000 hab)
0	34.51	63.96	0.52
1	47.50	39.89	2.29
2	39.24	52.66	0.67
3	30.61	76.50	0.19

4.6.2. Variables más influyentes

La separación entre clusters no se explica por una sola variable, sino por la combinación de varias dimensiones. En la matriz reducida utilizada para la interpretación, las variables con mayor capacidad discriminante fueron los hechos discriminatorios por habitante, la actividad económica, el porcentaje de vivienda pequeña, la renta media, el analfabetismo, el valor catastral, la densidad de población, los hogares unipersonales, la vivienda turística y la pobreza infantil.

En la matriz amplia jerarquizada, esta lectura se refuerza. Las variables que más diferencian grupos son, sobre todo, la densidad de empresas activas, la presencia de oficinas bancarias, la ocupación peatonal del espacio público, la intensidad de actividades económicas, el peso del trabajo autónomo, las terrazas de hostelería, la renta neta media y la dotación de itinerarios ciclistas. Dicho de otro modo, los clusters no solo distinguen niveles de renta o vulnerabilidad, sino también formas distintas de centralidad económica, especialización terciaria y estructura del espacio urbano.

Esta combinación de resultados permite resumir la lógica del modelo del siguiente modo. Ciutat Vella se separa por una mezcla extrema de centralidad turística, actividad económica y presión urbana. L'Eixample se diferencia por su posición residencial alta, su centralidad económica y su mayor dotación de servicios. El grupo de Jesús se define por densidad alta, rentas más modestas y un perfil intermedio de vulnerabilidad. Finalmente, Poblets del Sud destaca por baja densidad, mayor extensión territorial y menor compacidad funcional.

Por otro lado, como medida descriptiva de separación entre grupos se calcula eta cuadrado: proporción de variación de cada variable explicada por las diferencias entre clusters. No es un test causal; sirve para ordenar variables según su capacidad discriminante dentro de la partición obtenida.

De esta manera, se obtiene la siguiente distribución de categorías en el top 15 más influyentes:

Tabla 4.7: Variables más influyentes

Categoría	Recuento
Medio ambiente	1
Sociedad y Bienestar	4
Urbanismo e infraestructuras	2
Economía	4
Movilidad y transporte	1
Seguridad y convivencia	3

Esto nos muestra que las variables que más afectan son las de tipo económico y de bienestar, en especial variables que afectan al consumo público y la actividad comercial e industrial. Esto nos muestra que valores que reflejan la alta capacidad de movimiento económico son un factor clave para determinar el grado de afluencia de un distrito.

4.6.3. Variables menos influyentes

De este mismo análisis, se obtuvieron los resultados de las variables que menos afectan a la segmentación de los distritos. Estos resultados no implican que dichas variables carezcan de interés urbano, sino que, dentro de la partición obtenida, contribuyen menos a diferenciar unos clusters de otros.

Tabla 4.8: Variables menos influyentes

Categoría	Recuento
Medio ambiente	4
Sociedad y Bienestar	2
Urbanismo e infraestructuras	1
Demografía	4
Movilidad y transporte	1
Seguridad y convivencia	2
Educación	1

Las variables con menor capacidad discriminante se concentran principalmente en medio ambiente y demografía. Este resultado no implica que dichas dimensiones sean irrelevantes para el estudio urbano, sino que, en la partición obtenida, sus valores no separan los clusters con tanta claridad como las variables económicas, residenciales o de centralidad. En particular, algunos indicadores ambientales y de movilidad presentan variaciones menos marcadas entre distritos o captan fenómenos compartidos por buena parte del conjunto urbano.

4.6.4. Interpretación socioeconómica

Desde una perspectiva sustantiva, los clusters obtenidos muestran que la desigualdad urbana en Valencia no adopta una única forma lineal. Existen, al menos, tres mecanismos distintos. El primero es una desigualdad asociada a la centralidad económica y turística, visible en Ciutat Vella, donde la prosperidad relativa coexiste con tensión residencial y presión funcional. El segundo es una desigualdad más clásica, vinculada a renta, paro, pobreza infantil y posición residencial, especialmente clara en los distritos densos intermedios. El tercero corresponde a una periferia extensiva cuya especificidad depende tanto de la estructura territorial como de la menor centralidad de servicios y actividad.

Esta lectura conecta directamente con los objetivos del trabajo. El clustering permite traducir la tabla distrital final en una tipología interpretable de desigualdades territoriales,

identificar qué dimensiones diferencian mejor a los distritos y sugerir que la planificación urbana no debería tratar toda la vulnerabilidad de la misma forma. Algunas áreas requieren respuestas ligadas a cohesión social, acceso a oportunidades y mejora residencial; otras exigen gestionar presión turística, saturación funcional o desequilibrios entre usos económicos y habitacionales.

4.6.5. Limitaciones del modelo

Los resultados anteriores deben interpretarse con cautela. En primer lugar, el número de observaciones es reducido, ya que el análisis solo incluye 19 distritos. Esto limita la estabilidad estadística de cualquier partición y aconseja leer los clusters como una síntesis exploratoria rigurosa, no como una taxonomía definitiva.

En segundo lugar, la tabla final combina fuentes de años distintos, por lo que la fotografía obtenida es metodológicamente coherente pero no estrictamente sincrónica. En tercer lugar, las variables disponibles tienen granularidad desigual: algunas representan estructuras de largo plazo, mientras que otras recogen fenómenos más coyunturales o dependientes de registros administrativos. En cuarto lugar, el escalado *MinMax* mejora la comparabilidad, pero puede verse afectado por valores extremos y, por tanto, influir en la geometría del problema. Por último, *K-Means* presupone grupos convexos alrededor de centroides y no incorpora explícitamente continuidad espacial ni dependencia geográfica entre distritos colindantes.

Pese a estas limitaciones, el modelo cumple una función analítica relevante: muestra que la matriz distrital final contiene regularidades territoriales plausibles y que dichas regularidades pueden traducirse en perfiles urbanos útiles para estudiar desigualdad, vulnerabilidad y planificación en Valencia.

4.7. Comprobaciones adicionales de robustez

4.7.1. Solución con $k = 3$

Como contraste, se probó también una solución con $k = 3$. En este caso se obtuvieron grupos de tamaños 12, 4 y 3, representados respectivamente por Jesús, L'Eixample y Poblets del Sud. La principal diferencia respecto a la solución elegida es que Ciutat Vella deja de constituir un cluster propio y se integra en el grupo central asociado a L'Eixample.

Esta fusión reduce la capacidad del modelo para captar la singularidad funcional y

turística del centro histórico. Aunque la solución con tres grupos es más simple, pierde una distinción urbana relevante: la separación entre el eje central acomodado y el núcleo histórico sometido a mayor presión terciaria y residencial. Por esta razón, $k = 3$ resulta menos expresivo para los objetivos del trabajo.

4.7.2. Solución con $k = 5$

También se evaluó una solución con $k = 5$. En este caso aparecieron grupos de tamaños 8, 3, 5, 1 y 2, representados por Jesús, L'Eixample, Patraix, Ciutat Vella y Poblets del Sud. El resultado muestra que, al aumentar el número de clusters, el modelo tiende a subdividir el gran bloque de distritos intermedios en dos perfiles próximos entre sí, mientras que Ciutat Vella y L'Eixample mantienen su singularidad.

Esta prueba es útil porque confirma que existen submatrices dentro del grupo intermedio, pero también evidencia una pérdida de parsimonia. Con $k = 5$ la lectura territorial se vuelve más fragmentada y algunos grupos pasan a ser demasiado pequeños para sostener una interpretación robusta en una muestra de solo 19 distritos. Por ello, aunque la solución ampliada es interesante como comprobación adicional, $k = 4$ sigue ofreciendo el mejor equilibrio entre ajuste, interpretabilidad y coherencia urbana.

4.7.3. Comparación entre valores de k

La comparación entre particiones permite observar cómo cambia la asignación de distritos al modificar el valor de k y, con ello, reforzar la elección de $k = 4$. La Tabla 4.9 resume la clasificación obtenida para $k = 3$, $k = 4$ y $k = 5$:

Tabla 4.9: Comparación de asignación de distritos para $k = 3$, $k = 4$ y $k = 5$

Código	Nombre	cluster k=3	cluster k=4	cluster k=5
1	CIUTAT VELLA	1	1	1
2	L'EIXAMPLE	1	2	3
3	EXTRAMURS	1	2	3
4	CAMPANAR	0	0	0
5	LA SAIDIA	0	0	0
6	EL PLA DEL REAL	1	2	3
7	L'OLIVERETA	0	0	2
8	PATRAIX	0	0	0
9	JESUS	0	0	0
10	QUATRE CARRERES	0	0	0
11	POBLATS MARITIMS	0	0	0
12	CAMINS AL GRAU	0	0	0
13	ALGIROS	0	0	0
14	BENIMACLET	0	0	0
15	RASCANYA	0	0	2
16	BENICALAP	0	0	2
17	POBLATS DEL NORD	2	3	4
18	POBLATS DE L'OEST	2	3	2
19	POBLATS DEL SUD	2	3	4

La comparación muestra que la solución con $k = 3$ absorbe Ciutat Vella dentro del grupo central formado por L'Eixample, Extramurs y El Pla del Real, perdiendo así la singularidad del centro histórico. En cambio, al pasar a $k = 5$, la partición conserva los perfiles principales, pero fragmenta el grupo intermedio y desplaza algunos distritos hacia subgrupos más pequeños. Por ello, $k = 4$ mantiene una lectura más equilibrada: conserva la singularidad de Ciutat Vella, separa el eje central acomodado, identifica la periferia extensiva y evita una sobresegmentación difícil de interpretar.

5. Conclusiones y trabajo futuro

5.1. Conclusiones

Este trabajo ha permitido construir una base de datos distrital amplia, integrada y metodológicamente trazable para el estudio de las desigualdades urbanas en Valencia. La principal aportación no reside únicamente en reunir indicadores procedentes de fuentes heterogéneas, sino en transformarlos en una matriz comparable, interpretable y preparada para su explotación analítica y territorial.

A partir de esta base, la aplicación de técnicas de clustering ha permitido identificar perfiles distritales diferenciados que reflejan formas diversas de desigualdad urbana. En particular, la solución con $k = 4$ distingue un grupo amplio de distritos intermedios y densos, un perfil singular asociado a Ciutat Vella, un eje central de mayor renta y centralidad económica en torno a L'Eixample, y un grupo periférico-extensivo representado por Poblets del Sud. Esta tipología no debe interpretarse como una clasificación cerrada, pero sí como una síntesis útil para comprender regularidades territoriales complejas.

Los resultados obtenidos muestran, además, que la desigualdad urbana en Valencia no responde a un único patrón. Junto a diferencias clásicas ligadas a renta, paro o posición residencial, aparecen también contrastes relacionados con centralidad económica, presión turística, estructura funcional del espacio urbano y disponibilidad relativa de equipamientos y recursos. En este sentido, el análisis confirma que la vulnerabilidad territorial adopta configuraciones múltiples y que su interpretación requiere una lectura conjunta de dimensiones sociales, económicas y espaciales.

En conjunto, el trabajo ofrece una contribución metodológica y analítica útil para futuras investigaciones y para posibles aplicaciones de diagnóstico territorial. La combinación de depuración reproducible de datos, análisis multivariante e interpretación espacial constituye una base sólida para seguir profundizando en el estudio de la desigualdad urbana en Valencia y en otros contextos urbanos comparables.

5.2. Trabajo futuro

Como líneas de trabajo futuro, resultaría especialmente interesante ampliar el modelo en varias direcciones. En primer lugar, podría profundizarse en la explotación analítica de

la base de datos mediante la aplicación sistemática de técnicas de análisis de componentes principales, clustering y construcción de índices sintéticos de vulnerabilidad o prosperidad.

En segundo lugar, sería conveniente desarrollar una visualización interactiva más completa, que permitiera explorar simultáneamente mapas, perfiles distritales, agrupaciones y relaciones entre variables, facilitando tanto el análisis académico como su posible uso divulgativo o institucional.

En tercer lugar, una extensión natural del trabajo consistiría en replicar la metodología en otras ciudades españolas. Ello permitiría comparar estructuras territoriales de desigualdad en distintos contextos urbanos y avanzar hacia un marco de análisis más generalizable.

Por último, también sería interesante incorporar series temporales más completas y estudiar la evolución de las desigualdades urbanas en el tiempo, analizando no sólo la situación actual de los distritos, sino también sus trayectorias recientes.

6. Bibliografía

Ajuntament de València. (2025). *Portal de datos abiertos y geoportal de valència*. Descargado de <https://valencia.opendatasoft.com/> (Consultado en abril de 2026)

Arcarons, A. (2021). *Mapa de pobreza infantil*. Descargado de https://public.tableau.com/app/profile/albert.arcarons8487/viz/Mapa_PI/Nacional (Visualización pública en Tableau. Consultado en abril de 2026)

Benassi, F., y Iglesias-Pascual, R. (2023). Local-scale residential concentration and income inequalities of the main foreign-born population groups in the spanish urban space. reaffirming the model of a divided city. *Journal of Ethnic and Migration Studies*, 49(3), 673–696. doi: 10.1080/1369183X.2022.2067137

Bhahari, R. H., y Kusnawi. (2024). Clustering analysis of socio-economic districts/cities in east java province using pca and hierarchical clustering methods. *Sinkron: Jurnal dan Penelitian Teknik Informatika*, 8(4), 2242–2251. doi: 10.33395/sinkron.v8i4.14078

Cabrera-Barona, P., Murphy, T., Kienberger, S., y Blaschke, T. (2015). A multi-criteria spatial deprivation index to support health inequality analyses. *International Journal of Health Geographics*, 14(11). doi: 10.1186/s12942-015-0004-x

Feizizadeh, B., Blaschke, T., Lakes, J., y Tajbar, H. (2018). Urban vulnerability assessment: Advances from the strategic planning outlook. *Journal of Cleaner Production*, 179, 544–558. doi: 10.1016/j.jclepro.2018.01.088

Fernández, I. C., y Wu, J. (2016). Assessing environmental inequalities in the city of santiago (chile) with a hierarchical multiscale approach. *Applied Geography*, 74, 160–169. doi: 10.1016/j.apgeog.2016.07.012

Foroutan, E., Hu, T., Zhang, F., y Yu, H. (2024). Assessing heat vulnerability in philadelphia using geographically weighted principal component analysis (gwpca): A geospatial big data-driven approach. *International Journal of Applied Earth Observation and Geoinformation*, 127, 103653. doi: 10.1016/j.jag.2024.103653

Instituto Nacional de Estadística. (2025). *Indicadores urbanos y estadísticas territoriales*. Descargado de <https://www.ine.es/> (Consultado en abril de 2026)

- Logan, T. M., Anderson, M., Williams, T., Conrow, L., Patterson, M., y Krause, J. (2021). Measuring inequalities in urban systems: An approach for evaluating the distribution of amenities and burdens. *Computers, Environment and Urban Systems*, 86, 101590. doi: 10.1016/j.compenvurbsys.2020.101590
- Mazorra Rodríguez, Á. (2024). Social inequality and residential segregation trends in spanish global cities. a comparative analysis of madrid, barcelona, and valencia (2001–2021). *Cities*, 149, 104935. doi: 10.1016/j.cities.2024.104935
- Ministerio de Transportes, Movilidad y Agenda Urbana. (2022). *Atlas de vulnerabilidad urbana*. Descargado de <https://atlasvulnerabilidadurbana.fomento.gob.es/> (Consultado en abril de 2026)
- Vera, C., Lucchini, F., Bro, N., Mendoza, M., Löbel, H., Gutiérrez, F., . . . Toro, S. (2022). Learning to cluster urban areas: two competitive approaches and an empirical validation. *EPJ Data Science*, 11(62). doi: 10.1140/epjds/s13688-022-00374-2

A. Apéndice metodológico: materiales complementarios del pipeline

Este apéndice recoge los materiales complementarios asociados a la construcción, depuración, compactación, jerarquización y visualización de la base de datos distrital. Su finalidad no es repetir la explicación metodológica desarrollada en el cuerpo principal del trabajo, sino identificar de forma sintética los ficheros que permiten reconstruir el proceso seguido y reforzar su trazabilidad.

Todos estos materiales se encuentran disponibles en el repositorio GitHub del proyecto, accesible en: Repositorio del proyecto.

A efectos expositivos, los archivos complementarios pueden agruparse en cinco bloques.

A.1. Fuentes iniciales y estructura de partida

Este primer bloque documenta el punto de partida material de la base de datos y la reconstrucción de la tabla inicial:

- `manifiesto_fuentes_iniciales.csv`: inventario de fuentes iniciales utilizadas en la construcción de la tabla, con información sobre su origen, tipo de incorporación y trazabilidad.
- `resumen_fuentes_iniciales.md`: resumen metodológico de la recopilación inicial de fuentes y de la naturaleza híbrida del proceso.
- `tabla_distritos_inicial_scaffold.csv`: estructura base de la tabla distrital, con códigos y nombres de distrito y la fila auxiliar de categorías.

A.2. Scripts principales del pipeline

Los scripts en Python recogen la implementación operativa de las fases descritas en la memoria:

- `depurar_tabla.py`: limpieza, depuración y transformación de la tabla distrital.
- `correlaciones.py`: comprobaciones cuantitativas y análisis de correlaciones como apoyo a decisiones metodológicas.

- `jerarquizar_tabla.py`: clasificación de variables según bloque temático, subdimensión y rol analítico.
- `generar_mapa_interactivo.py`: generación del visor territorial a partir de la tabla final y de la geometría distrital.

A.3. Tablas finales generadas

Como resultado del proceso de depuración y jerarquización se generaron varias tablas principales. Estas tablas representan el punto de llegada del pipeline de construcción de datos y el punto de partida para las fases posteriores de análisis y visualización.

- `tabla_por_distritos_depurada_limpia.csv`: versión depurada de la matriz distrital preparada para el análisis multivariante, en la que se normalizó el formato decimal sustituyendo comas por puntos y se eliminaron los valores no utilizables para su tratamiento numérico en Python.
- `tabla_por_distritos_final_depurada.csv`: matriz distrital resultante tras la depuración de la tabla inicial, con las variables seleccionadas, normalizadas o agregadas.
- `tabla_por_distritos_final_jerarquizada.csv`: versión final de la matriz distrital, en la que se incorporan metadatos de bloque temático, subdimensión y rol analítico.

A.4. Ficheros de control metodológico

Este bloque reúne documentos auxiliares que permiten justificar y auditar las decisiones de reducción y compactación de variables:

- `reporte_correlaciones.csv`: correlaciones y comprobaciones cuantitativas empleadas como respaldo de decisiones de depuración.
- `decisiones_compactacion_tabla_amplia.csv`: registro de decisiones adoptadas durante la compactación de la tabla amplia.
- `variables_compactadas_bloques.csv`: relación de variables reorganizadas por bloques temáticos.

- `compactacion_tabla_amplia_justificada.md`: explicación narrativa de los criterios aplicados en la compactación.

A.5. Visualización interactiva

La visualización interactiva se conserva como producto complementario del pipeline, con una función principalmente exploratoria y comunicativa:

- `mapa_interactivo_distritos.html`: fichero de la visualización interactiva final conservado como material complementario.
- `map.html`: visualización interactiva de la tabla inicial.

En conjunto, estos materiales complementarios permiten reconstruir el recorrido seguido desde la recopilación inicial de fuentes hasta la obtención de una matriz distrital depurada, jerarquizada y preparada para su exploración territorial y análisis posterior. De este modo, el repositorio funciona como soporte reproducible del pipeline desarrollado en el TFM.

A.6. Notebook de análisis multivariante

Los resultados presentados en los apartados 4.5, 4.6 y 4.7 se basan en el notebook `analisis_multivariante_tfm.ipynb`, ubicado en la carpeta `01_codigo/` del repositorio del proyecto. Este cuaderno documenta de forma reproducible la fase de análisis multivariante aplicada sobre la matriz final jerarquizada.

El notebook contiene la carga de la tabla distrital final, la selección de variables activas, el tratamiento de la matriz numérica, el escalado de los indicadores mediante *MinMaxScaler*, el análisis exploratorio mediante PCA, el ajuste de K-Means para distintos valores de k , el cálculo de métricas de validación interna y la generación de las tablas utilizadas para interpretar los clusters. También incorpora comprobaciones de robustez mediante la comparación de soluciones con $k = 3$, $k = 4$ y $k = 5$, así como un contraste entre la matriz principal sin imputación y una versión imputada por mediana.

Su función principal es dejar trazable el cálculo de los resultados analíticos del capítulo 4: las métricas de inercia, silueta y Davies-Bouldin, la asignación de distritos a cada cluster, la representación mediante PCA y el cálculo de las variables con mayor y menor

capacidad discriminante. De este modo, las conclusiones de los apartados 4.5, 4.6 y 4.7 quedan vinculadas a un soporte computacional verificable y reutilizable.